



# Automatische Sexismusdetektion in deutschsprachigen Texten

Vorstellung der Bachelorarbeit  
23.08.2024, 11:00 Uhr

Markus Byhan



**HOCHSCHULE  
MITTWEIDA**  
University of Applied Sciences



[hs-mittweida.de](https://www.hs-mittweida.de)

# Ist Sexismus überhaupt ein Thema?

In den 50er, 60er und 70er Jahren:


Heute anders?



# Die Bedeutung von Online-Medien

Die Nutzung digitaler Inhalte:

Digitale Medien



Social Media

Tabelle 4  
Nutzung von Social-Media-Plattformen 2019 bis 2023 – mindestens einmal wöchentlich genutzt  
in %

|            | Gesamt |      |      |      |      |        |        | 2023     |          |          |          |      |
|------------|--------|------|------|------|------|--------|--------|----------|----------|----------|----------|------|
|            | 2019   | 2020 | 2021 | 2022 | 2023 | 2023   | 2023   | 2023     | 2023     | 2023     | 2023     | 2023 |
|            |        |      |      |      |      | Frauen | Männer | 14-29 J. | 30-49 J. | 50-69 J. | ab 70 J. |      |
| Instagram  | 19     | 20   | 26   | 31   | 35   | 36     | 33     | 79       | 46       | 15       | 5        |      |
| Facebook   | 31     | 26   | 28   | 35   | 33   | 34     | 33     | 34       | 50       | 28       | 14       |      |
| TikTok     | 2      | 3    | 9    | 14   | 15   | 17     | 14     | 41       | 18       | 4        | 2        |      |
| Snapchat   | 8      | 9    | 10   | 13   | 13   | 13     | 13     | 52       | 9        | 1        | 1        |      |
| Pinterest* | –      | –    | 7    | 10   | 11   | 17     | 5      | 23       | 15       | 6        | 4        |      |
| Twitter    | 4      | 5    | 4    | 10   | 8    | 5      | 11     | 14       | 12       | 4        | 2        |      |
| LinkedIn   | 2      | 4    | 3    | 6    | 7    | 5      | 9      | 12       | 11       | 3        | 0        |      |
| Twitch     | 4      | 3    | 5    | 7    | 6    | 3      | 9      | 17       | 8        | 1        | 0        |      |
| reddit*    | –      | –    | –    | 4    | 5    | 2      | 7      | 15       | 5        | 0        | 0        |      |
| BeReal*    | –      | –    | –    | –    | 4    | 5      | 4      | 18       | 3        | 0        | 0        |      |
| Xing       | 3      | 4    | 3    | 4    | 4    | 2      | 5      | 7        | 5        | 2        | 1        |      |
| Mastodon*  | –      | –    | –    | –    | 2    | 2      | 2      | 3        | 3        | 0        | 1        |      |

\* in früheren Jahren teilweise nicht erfasst.  
Basis: Deutschspr. Bevölkerung ab 14 Jahren (2023: n=2.000; 2022: n=2.007; 2021: n=2.001; 2020: n= 3.003; 2019: n= 2.000).  
Quellen: ARD/ZDF-Onlinestudien 2019 bis 2023.

# Herausforderungen bei der Erkennung von Sexismus in Texten

## Ausprägungen und Erscheinungsformen

- Subtile / versteckte Form
- Kontextinterpretation notwendig

## Umfang an Texten

- Kommentierungsmöglichkeiten können einfach genutzt werden
- Missbrauch der Kommentarfunktion zur Verbreitung von Hassrede

## Geschwindigkeit von Postings

- Nachrichten werden i. d. R. sofort kommentiert

## Verbreitung und Reichweite von Postings


- Schutz der Kommentatoren durch Anonymität
- Häufig abruf- und teilbar auch ohne Anmeldung
- Großer Leserkreis

## Zielsetzung:

Automatische Identifikation und Entfernung von „Hate – Speech“ von Webseiten




# Was war die Aufgabe?





# Roadmap und zeitlicher Projektplan

## Zeitlicher Ablauf der GermEval 2024



## Ableitung für die Bachelorarbeit



# Forschungsstand „Hate – Speech“

## GermEval 2018 - aktuell

- Klassifikation von Sprache, insbesondere offensive Sprache
- i. d. R. Binär- und feingranulare Klassifikation

## IberLEF Shared Task: EXIST (sEXism Identification in Social neTworks)

- Sexistische Ausdrücke in Tweets
- Binär- und feingranulare Klassifikation

## SemEval 2023 Shared Task 10: Explainable Detection of Online Sexism (EDOS)

- Datenbasis Gab und Reddit
- Binär- und feingranulare Klassifikation (11 Vektoren)




## Erfolgreiche Machine – Learning Konzepte:

- ✓ Klassische Verfahren (SVM, RF)
- ✓ Transformerbasierte Verfahren (BERT, mBERT, DeBERTa und weitere Variationen)

# Ausgewählte ML – Algorithmen


## Support Vector Machine

- ✓ Hohe Genauigkeit
- ✓ Fähigkeit, mit hochdimensionalen Daten umzugehen
- ✓ Gute Unterstützung durch Bibliotheken



## Random Forest



- ✓ Besteht aus gut verständlichen Decision Trees
- ✓ Gute Vorhersagegenauigkeit durch Kombination von einzelnen Entscheidungsbäume
- ✓ Robustheit gegen Overfitting





# Annotationsschemata

Einstufung der Texte durch Annotatoren:



# Forschungsthema und Zielsetzung

Frage 1:



Lassen sich durch die verwendeten Machine-Learning-Modelle und Mehrheitsstrategien Rückschlüsse darauf ziehen, inwieweit die Meinungen von Annotatoren bei Anwendung auf einen neuen Text divergieren?

Frage 2:


Welche der beiden traditionellen Algorithmen - SVM oder Random-Forest - liefert bessere Ergebnisse bei der Klassifikation unter Verwendung verschiedener Strategien und inwiefern führt das Fine-Tuning von Hyperparametern zu Performance-Verbesserungen?




# Herausforderungen in der Vorverarbeitung



Identifikation von Ausreißern durch Z-Score Berechnung



# Herausforderungen in der Vorverarbeitung



Handhabung von fehlenden Werten durch k-NN Imputation:

1. Identifikation der fehlenden Werte
2. Berechnung euklidische Distanz
3. Bestimmung der k-nächsten Nachbarn
4. Imputation
5. Mehrere Iterationen





# Training und Ergebnisse

## Training

### Feature-Engineering

22 Features durch TF-IDF

10 Features durch Sentimentanalyse



## Ergebnisse (Macro-F1-Score)

### Support Vector Machine:

Unabhängig von Optimierungsmaßnahmen

Top: 0.6252 (bin\_one)

Flop: 0.1689 (multi\_maj) / keine Ermittlung

### Random Forest

Ohne Hyperparametertuning:

Top: 0.7044 (bin\_one)

Flop: 0.2308 (multi\_maj)

Mit Hyperparametertuning:

Top: 0.7441 (bin\_maj)

Flop: 0.1691 (multi\_maj)

# Herausforderungen

## Datensatz und Modelltraining

- Datenqualität und -umfang
- Ungleichgewicht der Klassen
- Sentimentanalyse und emotionale Nuancen

## Anwender

- Zu hoher Aufwand in der Datenvorverarbeitung
- Probleme, den Gesamtzusammenhang zu erkennen
- Feature-Selektion und Modellkomplexität
- Sentimentanalyse und emotionale Nuancen
- Nur Subtask 1 bearbeitet

## Aber:

- Straffer Zeitplan führte zu kontinuierlicher Leistungserbringung
- Regelmäßiger Support verhinderte längere Unterbrechungen



# Fazit

## Fragestellung 1:

- Hinweise sind erkennbar
- Performance bei multi\_maj sehr schlecht, bin\_all ebenfalls



Erfordert weitere Untersuchungen, insbesondere Detailanalysen zu Annotatorenvarianz bei neuen Texten

## Fragestellung 2:

- Random Forest mit besserer Performance
- Parameteroptimierung führte zu Verbesserungen

# Vielen Dank



**HOCHSCHULE  
MITTWEIDA**  
University of Applied Sciences

Markus Byhan  
Student IT Forensik & Cybercrime  
Seminargruppe: CC20w1-B

**Hochschule Mittweida** | University of Applied Sciences  
Technikumplatz 17 | 09648 Mittweida  
Fakultät Angewandte Computer- und Biowissenschaften

**T** +49 (0) 421 240 30 69  
**M** +49 (0) 1525 675 0124  
mbyhan@hs-mittweida.de

[hs-mittweida.de](https://www.hs-mittweida.de)