



BACHELORARBEIT

Herr
Markus Byhan

Automatische Sexismusdetektion in deutschsprachigen Texten

Mittweida, August 2024

BACHELORARBEIT

Automatische Sexismusdetektion in deutschsprachigen Texten

Autor:

Markus Byhan

Studiengang:

IT-Forensik/Cybercrime

Seminargruppe:

CC20w1-B

Erstprüfer:

Prof. Dr. rer. nat. Michael Spranger

Zweitprüferin:

Jenny Felser, M.Sc.

Einreichung:

Mittweida, 09.08.2024

Verteidigung/Bewertung:

Mittweida, 2024

BACHELOR THESIS

Automatic sexism detection in German-language texts

Author:

Markus Byhan

Course of Study:

IT-Forensics/Cybercrime

Seminar Group:

CC20w1-B

First Examiner:

Prof. Dr. rer. nat. Michael Spranger

Second Examiner:

Jenny Felser, M.Sc.

Submission:

Mittweida, 09.08.2024

Defense/Evaluation:

Mittweida, 2024

Bibliografische Beschreibung

Byhan, Markus:

Automatische Sexismusdetektion in deutschsprachigen Texten. – 2024. – 47 S.

Mittweida, Hochschule Mittweida – University of Applied Sciences, Fakultät Angewandte Computer- und Biowissenschaften, Bachelorarbeit, 2024.

Referat

Das automatische Erkennen von Sexismus in Texten ist entscheidend für die Schaffung einer sicheren und inklusiveren Online-Umgebung. Diskriminierende Inhalte können sich schnell über öffentliche Kommunikationsplattformen verbreiten und stellen aufgrund der enormen Datenmengen erhebliche Herausforderungen für die manuelle Moderation dar. Maschinelle Lerntechniken (ML) bieten eine effiziente Lösung, indem sie die Echtzeiterkennung und -entfernung sexistischer Bemerkungen ermöglichen und somit Einzelpersonen schützen und Gemeinschaftsstandards aufrechterhalten. Die in dieser Arbeit für unterschiedliche Strategien trainierten Modelle basieren auf einer Feature-Selektion, bestehend aus einer „Frequency-Inverse Document Frequency“ (TF-IDF) und auf Basis einer Sentimentanalyse. Bei der TF-IDF wurden 22 Wörter als Features gewichtet und berücksichtigt, bei der Sentimentanalyse insgesamt zehn Wörter, die sich aus acht Emotionen sowie zwei allgemeinen Klassifikationen (positiv/negativ) zusammensetzten. Die Modelle wurden für den Subtask 1 der GermEval 2024 trainiert, dessen Zielsetzung aus einer Binärklassifizierung (sexistischer Text: ja/nein) bestand.

Das beste Modell war ein Random-Forest-Modell, das nach Hyperparametertuning für die Vorhersage, ob die Mehrheit der Annotatoren den Kommentar als sexistisch einstufte, einen Macro-F1 von 0.7441 erreichte. Ein ebenfalls gutes Ergebnis konnte mit einem Random-Forest-Modell für die Vorhersage, ob einer der Annotatoren den Kommentar als sexistisch eingestuft hat, erzielt werden. Der Macro-F1 - Score betrug dabei 0.719.

Inhaltsverzeichnis

Inhaltsverzeichnis	I
Abbildungsverzeichnis	III
Tabellenverzeichnis	IV
1 Einleitung	1
1.1 Hintergrund und Motivation	1
1.2 Problemstellung und Ziele der Arbeit	3
1.3 Aufbau der Arbeit	4
2 Grundlagen	5
2.1 Überblick über maschinelles Lernen	5
2.1.1 Überwachtes Lernen	6
2.1.2 Unüberwachtes Lernen	8
2.1.3 Verstärkendes Lernen	8
2.1.4 Deep Learning	8
2.2 Ausgewählte traditionelle Klassifikationsalgorithmen	9
2.2.1 Support Vector Machines (SVM)	9
2.2.2 Random Forests (RF)	12
2.3 Textklassifikation	14
2.4 Evaluation	15
2.4.1 Evaluationsmetriken	15
2.4.2 Cross-Validation	17
2.5 Definition von Sexismus und seine Formen	18
2.6 Grundlagen der Sentimentanalyse	20
2.7 Die Detektion von Sexismus in Texten	22
3 Verwandte Arbeiten	23
3.1 Forschungsarbeiten zu Hate-Speech und Sexismusdetektion	23
3.2 Vergleich von Shared Tasks zur Sexismusdetektion	24
3.3 Fazit der Literaturanalyse	25
4 Daten und Methodik	26
4.1 Beschreibung der Daten	26
4.1.1 Explorative Datenanalyse	27
4.1.2 Annotationsschema von Subtask 1	28
4.1.2.1 Ungleichverteilung der Label	28
4.1.2.2 Varianz in den Klassifikationen	29
4.1.2.3 Strategie 1: bin_maj	30
4.1.2.4 Strategie 2: bin_one	31
4.1.2.5 Strategie 3: bin_all	31
4.1.2.6 Strategie 4: multi_maj	31
4.1.2.7 Strategie 5: disagree_bin	31

4.2	Vorverarbeitung	32
4.2.1	Identifikation von Ausreißern	33
4.2.2	Handhabung von fehlenden Werten	34
4.3	Feature-Engineering	35
4.3.1	Textrepräsentation durch TF-IDF	35
4.3.2	Sentimentanalyse	36
4.4	Modellauswahl und -training	37
4.4.1	Hyperparametertuning der Support Vector Machines	37
4.4.2	Hyperparametertuning des Random Forest	38
5	Ergebnisse und Diskussion	39
5.1	Ergebnisse der SVM	39
5.1.1	Ergebnisse ohne Hyperparametertuning (SVM)	39
5.1.2	Ergebnisse mit Hyperparametertuning (SVM)	40
5.2	Ergebnisse der RF	41
5.2.1	Ergebnisse ohne Hyperparametertuning (RF)	41
5.2.2	Ergebnisse mit Hyperparametertuning (RF)	42
5.3	Vergleich der Modelle	43
5.4	Herausforderungen und Limitationen	44
5.5	Potentielle Verbesserungen und zukünftige Arbeiten	45
6	Fazit und Ausblick	46
	Literaturverzeichnis	48
	Eidesstattliche Erklärung	54

Abbildungsverzeichnis

1.1	Formen von Online-Belästigungen nach Geschlecht. Quelle: (Duggan, 2014)	1
1.2	Verteilung von Narrativen in Tiktok-Videos. Quelle: (Dolezalek et al., 2024)	3
2.1	Gebiete der künstlichen Intelligenz. Quelle: (Krutzfeldt, 2023)	5
2.2	Methoden des Maschinellen Lernens. Quelle: (Kiss, 2020)	6
2.3	Konzept der Support Vector Machines. Quelle: (Gandhi, 2018)	9
2.4	Kernel Trick für höherdimensionale Räume. Quelle: (Gandhi, 2018)	11
2.5	Konzept des Random Forest - Algorithmus. Quelle: (Brital, 2021)	12
2.6	Schema zur Entwicklung eines Machine - Learning - Modells. Quelle: (Mittal, 2017)	14
2.7	Plutchik's Rad der Emotionen. Quelle: (Plutchik, 1980)	21
4.1	Anzahl an Wörtern je Text	27
4.2	Labelverteilung über den Textkorpus	27
4.3	Überblick über die Ungleichverteilung der Label	28
4.4	Verteilung der Sentiment - Scores über den Korpus	37

Tabellenverzeichnis

2.1	Unterschiede zwischen Klassifikation und Regression, Quelle: (Brownlee, 2017)	7
4.1	Datenstruktur, ohne Vorverarbeitung	26
4.2	Datenstruktur, Labelverteilung	27
4.3	Beispiel 1: Breite in den Einstufungen von Texten	29
4.4	Beispiel 2: Breite in den Einstufungen von Texten	29
4.5	Beispiel 3: Breite in den Einstufungen von Texten	30
4.6	Vorhersagestrategie 1: <code>bin_maj</code>	30
4.7	Vorhersagestrategie 2: <code>bin_one</code>	31
4.8	Vorhersagestrategie 3: <code>bin_all</code>	31
4.9	Vorhersagestrategie 4: <code>multi_maj</code>	31
4.10	Vorhersagestrategie 5: <code>disagree_bin</code>	32
4.11	Verteilung der Anzahl an Bewertungen je Text	34
5.1	Ergebnisse des Trainings mit SVM für die fünf Strategien	40
5.2	Evaluation der finalen SVM - Modelle nach Hyperparameter-Tuning	41
5.3	Ergebnisse des Trainings mit RF für die fünf Strategien	42
5.4	Evaluation der finalen RF - Modelle nach Hyperparameter-Tuning	43

1 Einleitung


Die vorliegende Arbeit befasst sich mit der automatischen Detektion von Sexismus in deutschsprachigen Texten durch die Klassifikationsalgorithmen *Support Vector Machine (SVM)* und *Random Forest (RF)*. Zu Beginn der Hinweis, dass Begriffe wie „Online-Belästigung“, „Hate Speech“ oder „offensive Sprache“ im Kontext der automatisierten Detektion teils synonym verwendet werden auch wenn sie unterschiedliche Nuancen aufweisen. Der Themenkomplex „Sexismus“ ist dabei als spezifische Untergruppe zu betrachten.

1.1 Hintergrund und Motivation

Im Oktober 2014 veröffentlichte das Pew Research Center ¹ eine Studie zum Thema „Online Harassment“ (Duggan, 2014). Zu den wichtigsten Erkenntnissen dieser Untersuchung zählte die Erhebung der Erfahrungen junger Erwachsener zwischen 18 und 29 Jahren mit Belästigungen im digitalen Raum. Diese Personen sind mit größerer Wahrscheinlichkeit als jede andere demographische Gruppe von Online-Belästigung betroffen. In dieser Gruppe lag der Anteil derer, die bereits das Ziel solcher Übergriffe waren, bei 65 %. Wie in [Abbildung 1.1](#) ersichtlich, ist bei jungen Frauen im Alter zwischen 18 und 24 Jahren vor allem der große Anteil an Stalking und sexuellen Belästigungen auffällig:

Young women experience particularly severe forms of online harassment

Among all internet users, the % who have personally experienced the following types of online harassment, by gender and age...



Source: American Trends Panel (wave 4). Survey conducted May 30-June 30, 2014. n=2,839.

PEW RESEARCH CENTER

Abbildung 1.1: Dargestellt sind die Erfahrungen von jungen Personen mit Online-Belästigung laut Pew - Studie aus dem Jahr 2014

¹ Laut Eigendarstellung eine überparteiliche, amerikanische Forschungseinrichtung, die die Öffentlichkeit über Themen, Einstellungen und Trends informiert.

Auf die Frage, wo vor allem Belästigungen auftraten, gaben Betroffene mit 66 % und somit am häufigsten Social-Media-Seiten bzw. Apps an. Kommentarbereiche auf Webseiten folgten mit 22 %. Diese Plattformen sind folglich ein klarer Schwerpunkt bei der Verwendung von offensiver Sprache. Es ist außerdem zu berücksichtigen, dass die vorliegende Studie mittlerweile zehn Jahre alt ist und die Durchdringung von Social Media und Webinhalten seitdem deutlich zugenommen hat. Es ist daher anzunehmen, dass sich die Problematik eher verschärft als entspannt hat.

Eine weitere Annäherung an das Thema „Online-Sexismus“ ermöglicht die aktuelle Studie „Tracing Online Misogyny“ (Dolezalek et al., 2024). Diese bietet eine umfassende Analyse von Frauenfeindlichkeit im Internet aus einer deutsch-internationalen Perspektive. Sie beleuchtet verschiedene Aspekte und Facetten von Misogynie, die sich in unterschiedlichen ideologischen Grundlagen, Angriffsmethoden und subkulturellen Netzwerken abbilden. Der Bericht betont die Dringlichkeit des Themas und zeigt, dass Frauen systematisch und in alarmierendem Ausmaß Opfer von digitalem Hass und Gewalt werden. Die Angriffe reichen dabei von Beleidigungen und Bedrohungen über Desinformationen bis hin zu physischen Übergriffen.

Frauen in öffentlichen Positionen oder Rollen, wie Politikerinnen, Journalistinnen und Aktivistinnen, sind besonders häufig Ziel solcher Angriffe. Aber auch Frauen im Allgemeinen, die online identifiziert werden können, werden aufgrund ihres Geschlechts attackiert. Die Formen der Angriffe sind vielfältig und überschneiden sich oft: von abwertenden Kommentaren über das Aussehen und den intellektuellen Fähigkeiten bis hin zu sexualisierten Beleidigungen und Drohungen. Diese Angriffe haben nicht nur psychologische Auswirkungen, sondern können auch zu realen physischen Gefahren führen.

Die Studie kategorisiert verschiedene Subkulturen innerhalb der sogenannten „Manosphere“, die aktiv Frauenfeindlichkeit fördern. Zu diesen Subkulturen gehören die „Red Pill“-Bewegung, die traditionelle Geschlechterrollen und Verschwörungstheorien propagiert, die „Pick-Up Artists“ (PUA), die Techniken zur Manipulation und Eroberung von Frauen verbreiten, und die „Incels“, eine besonders radikale Gruppe, die Hass und Gewalt gegen Frauen rechtfertigt. Weitere Subkulturen wie „Men Going Their Own Way“ (MGTOW) streben nach vollständiger Unabhängigkeit von Frauen und dem Staat und lehnen jegliche Form von Geschlechtergleichstellung ab.

Die Datengrundlage bestand aus über zehn Millionen Nachrichten aus den Sprachen Englisch, Deutsch, Französisch, Niederländisch und Slowakisch, die aus unterschiedlichen Online-Quellen erfasst wurden.

Bedenklich ist in diesem Zusammenhang die Reichweite, die einzelne Subkulturen erreichen. Beispielsweise wurden Accounts auf Tiktok aus dem Bereich „Pick-Up Artists“ und „Life Coaches“ untersucht. Die analysierten elf Accounts hatten insgesamt über 256.801 Follower, 4,3 Millionen Video-Likes und mehr als 71,8 Millionen Video-Views (Dolezalek et al., 2024). Diese Reichweite, in Verbindung mit den Inhalten, die in den Videos thematisiert werden, lassen den Einfluss auf ihr in der Regel junges Publikum erahnen. [Abbildung 1.2](#) zeigt dazu die Verteilung der Narrative in den Videos:

Narrative




Abbildung 1.2: Dargestellt werden die Inhalte, die in den Videos der ausgewählten elf Tiktok-Accounts thematisiert wurden.

Ein zentraler Punkt der Studie ist die Feststellung, dass es bisher nur wenige Mechanismen gibt, die Frauen effektiv vor digitalem Hass schützen. Dies macht die Forschung zur automatischen Detektion von Sexismus besonders relevant und notwendig. Die Quantifizierung und systematische Erkennung von frauenfeindlichen Inhalten im Internet ist ein wichtiger Schritt, um Gegenmaßnahmen entwickeln zu können. Automatische Detektionssysteme könnten dazu beitragen, frauenfeindliche Kommentare und Inhalte in Echtzeit zu identifizieren und zu entfernen, bevor sie größeren Schaden anrichten. Die Untersuchung zeigt auch, dass Online-Misogynie nicht nur eine Spiegelung von Offline-Verhalten ist, sondern eine eigenständige Dynamik besitzt, die extremistische Ideologien fördern kann. Dies unterstreicht die Notwendigkeit, digitale Räume sicherer und inklusiver zu gestalten, um den öffentlichen Diskurs für alle Menschen zugänglich zu machen und gleichzeitig die Verbreitung von Hass und Gewalt einzudämmen.

1.2 Problemstellung und Ziele der Arbeit

Die vorliegende Bachelorarbeit befasste sich mit der Entwicklung und Evaluation von Klassifikatoren zur Erkennung von Sexismus und Misogynie in Online-Komentaren, die in deutscher Sprache im Kommentarbereich einer österreichischen Online-Zeitung veröffentlicht wurden (Krenn et al., 2024). Die Herausforderung bestand darin, einen Algorithmus zu entwickeln, der in der Lage ist, subtilen und impliziten Sexismus zu identifizieren, welcher sich oft der direkten Erkennung durch Vermeidung offensichtlich beleidigender Sprache entzieht. Die Arbeit stützte sich dabei auf einen bestehenden Korpus, der von menschlichen Annotatoren hinsichtlich des Vorhandenseins und der Intensität von Sexismus und Misogynie bewertet wurde. Ein besonderer Fokus lag auf der Handhabung und Interpretation abweichender Meinungen der Annotatoren. Es sollten robuste Modelle trainiert werden, die auch die Meinungsvielfalt in der Bewertung neuer Texte abbilden konnten. Daraus ergaben sich zwei Fragestellungen, die im Zuge dieser Arbeit untersucht werden sollten:

1. Lassen sich durch die verwendeten Machine-Learning-Modelle und Mehrheitsstrategien Rückschlüsse darauf ziehen inwieweit die Meinungen von Annotatoren bei Anwendung auf einen neuen Text divergieren?

2. - Welche der beiden traditionellen Algorithmen - SVM oder Random-Forest - liefert bessere Ergebnisse bei der Klassifikation unter Verwendung verschiedener Strategien und inwiefern führt das Fine-Tuning von Hyperparametern zu Performance-Verbesserungen?

Die in dieser Arbeit verfolgte Zielsetzung leitet sich direkt aus der Aufgabenstellung des Subtask 1 der GermEval 2024 ab und umfasst (Krenn et al., 2024):

Die Entwicklung von Klassifikatoren zur Vorhersage eines binären Labels, dass das Vorhandensein oder Nichtvorhandensein von Sexismus anzeigt. Bei den gelabelten Trainingsdaten basiert dabei das binäre Label auf verschiedenen Strategien zur Mehrheitsbildung der individuellen Einstufungen der Annotatoren. Beispielsweise wird bei Strategie „bin_one“ ein Text als sexistisch klassifiziert, wenn mindestens ein Annotator den Text als sexistisch gekennzeichnet hat. Nur bei einstimmiger Bewertung aller Annotatoren, dass der Text nicht sexistisch ist, wird dieser auch entsprechend gelabelt. Es zählt dabei die grundsätzliche Einstufung, die Ausprägung der Schwere des Sexismus durch ein Label von 1 bis 4 spielt keine Rolle. In diesem Zusammenhang soll außerdem untersucht werden, wie die Mehrheitsmeinung effektiv für die Klassifizierung genutzt werden kann.

Dazu werden aus den vorliegenden gelabelten Trainingsdaten mittels *Term Frequency - Inverse Document Frequency (TF-IDF)* Wörter bzw. Features bestimmt, die besondere Bedeutung in einem Dokument relativ zum gesamten Textkorpus aufweisen. Zusätzlich werden die Texte auf vorkommende Emotionen und grundlegende Textstimmung (positiv/negativ) mittels Sentimentanalyse untersucht und als Features mit der TF-IDF kombiniert. Ausgehend von dieser Featurezusammenstellung werden SVM- und Random Forest-Modelle für alle fünf Annotationsstrategien trainiert und evaluiert.

1.3 Aufbau der Arbeit

Die vorliegende Bachelorarbeit ist in sechs Kapitel gegliedert:

[Kapitel 1](#) führt in das Thema ein. Dabei werden die Hintergründe, die Motivation sowie die wissenschaftliche Problemstellung vorgestellt. In [Kapitel 2](#) werden grundlegende Informationen zu den Verfahren und Methoden des maschinellen Lernens erläutert und darüber hinaus die beiden Algorithmen, *Support Vector Machine* und *Random Forest* vorgestellt, da diese im Rahmen der Arbeit verwendet wurden. Es folgt eine Betrachtung des Themengebietes des Online-Sexismus und dessen Ausprägungen sowie eine Beschreibung der Sentimentanalyse und deren Relevanz bei der Textklassifikation. [Kapitel 3](#) bietet einen umfassenden Überblick über vergleichbare Aufgabenstellungen und Forschungsarbeiten zur automatischen Detektion von Hate Speech und Sexismus. [Kapitel 4](#) beginnt mit einer Vorstellung des verwendeten Datensatzes und dessen spezifischen Besonderheiten. Im Anschluss folgt eine explorative Datenanalyse und es werden die fünf Strategien zur Mehrheitsfindung der Annotationen erläutert. Danach werden Techniken und Vorgehen zum Umgang mit Ausreißern und fehlenden Werten vorgestellt und angewandt. Zusätzlich werden die ausgewählten Features erläutert, die zum Training der Modelle verwendet wurden und mögliche Ansätze zur Parameteroptimierung getestet. In [Kapitel 5](#) werden die Ergebnisse der beiden Aufgabenstellungen und der beiden Modelle präsentiert. Neben dem ursprünglich trainierten Modell werden Parameter zur Performanceverbesserung sowie deren Einfluss auf die Modellbewertung erläutert. Danach werden diese Ergebnisse verglichen und diskutiert. Es folgt eine kritische Betrachtung der Limitationen und der Herausforderungen, die die Ergebnisse beeinflusst haben, sowie Vorschläge, wie diese bei zukünftigen Experimenten verbessert werden könnten. Die Arbeit schließt mit [Kapitel 6](#) ab, welches ein Fazit zieht und einen Ausblick auf mögliche weiterführende Forschungen gibt.

2 Grundlagen

Das Kapitel gibt einen allgemeinen Überblick über das Themengebiet des maschinellen Lernens. Ergänzt wird der Abschnitt von der Vorstellung der beiden, für die Aufgabenstellung verwendeten Algorithmen: *Support Vector Machines* und *Random Forest*. Der zweite Teil erläutert die Grundlagen von Sexismus und die Herausforderungen bei dessen automatischer Detektion.

2.1 Überblick über maschinelles Lernen

Der Begriff „maschinelles Lernen“ ist in den letzten Jahren verstärkt in das Bewusstsein der Öffentlichkeit gerückt. Daher ist vorab zu bestimmen, wie dieser Bereich im Kontext der künstlichen Intelligenz eingeordnet werden kann. Häufig wird als minimale Strukturierung das maschinelle Lernen als Teilgebiet innerhalb der künstlichen Intelligenz verortet und Deep Learning wiederum als Teilgebiet des maschinellen Lernens. [Abbildung 2.1](#) zeigt, wie die einzelnen Gebiete miteinander in Verbindung stehen:




Abbildung 2.1: Dargestellt wird, dass Deep Learning als Teilgebiet des Machine Learnings und dieses wiederum als Teilbereich der künstlichen Intelligenz aufgefasst wird.

Die verwendeten Methoden des maschinellen Lernens lassen sich in drei Gruppen aufteilen:

1. Überwachtes Lernen
2. Unüberwachtes Lernen
3. Verstärkendes Lernen

Abbildung 2.2 führt zusätzlich Deep Learning als Methodik auf, dass in Form von neuronalen Netze in allen drei Gruppen vertreten ist:




Abbildung 2.2: Abgebildet sind die drei übergeordneten Methoden aus dem Themenkomplex Maschinelles Lernen sowie Deep Learning.

2.1.1 Überwachtes Lernen

Überwachtes Lernen ist eine der grundlegenden Methoden im maschinellen Lernen, bei der ein Modell auf Basis eines Trainingsdatensatzes, der sowohl Eingabe- als auch Ausgabeinformationen enthält, trainiert wird (Q. Liu & Wu, 2012). Bei den in dieser Arbeit verwendeten Trainingsdaten bilden die als einzelne Sätze aufgeführten Kommentare die Eingabeinformationen. Die Bewertung des Textes hinsichtlich dessen Sexismusausprägung ergibt die Ausgabeinformation. Ziel ist es, Muster oder Zusammenhänge in den Daten zu identifizieren, um Vorhersagen auf neuen, unbekannten Daten zu treffen. Überwachtes Lernen kann in zwei Hauptkategorien unterteilt werden: Klassifikation und Regression (James et al., 2013):

Klassifikation

Klassifikation ist eine Methode des überwachten Lernens, bei der das Ziel darin besteht, Eingabedaten in eine von mehreren vordefinierten Kategorien oder Klassen zuzuordnen (Saraswat, 2022). Die Ausgabedaten sind diskret und kategorisch. Beispiele dazu sind:

- Binäre Klassifikation: Ein E-Mail-System, das E-Mails als „Spam“ oder „Nicht-Spam“ klassifiziert.
- Mehrklassenklassifikation: Ein Bilderkennungsprogramm, das Bilder in verschiedene Kategorien wie „Hund“, „Katze“ oder „Vogel“ einteilt.

Algorithmen

Mittels folgender Algorithmen und Methoden kann beispielsweise die Klassifikation realisiert werden:

- Logistische Regression: Ein Algorithmus, der die Wahrscheinlichkeit eines Datenpunktes berechnet, zu einer bestimmten Klasse zu gehören.
- Support Vector Machines (SVM): Ein Algorithmus, der eine optimale Trennlinie zwischen den Klassen findet.
- Entscheidungsbäume: Ein Modell, das Daten anhand von Entscheidungsregeln aufteilt.
- K-nearest Neighbors (k-NN): Ein Algorithmus, der die Klassifizierung basierend auf den Klassen der nächsten Nachbarn trifft.
- Neuronale Netze: Künstliche Neuronale Netze sind massive parallele, miteinander verbundene Netze aus einfachen (in der Regel adaptiven) Elementen und deren hierarchischen Organisationen die mit den Objekten der realen Welt interagieren sollen so wie es biologische Systeme tun (Kohonen, 1988).

Regression

Regression ist eine Methode des überwachten Lernens, bei der das Ziel darin besteht, eine kontinuierliche Ausgabevariable vorherzusagen (Verdhan, 2020). Die Ausgabedaten sind numerisch und kontinuierlich. Beispiele dazu sind:

- Vorhersage der Hauspreise basierend auf Merkmalen wie Größe, Lage und Alter des Hauses.
- Schätzung des Umsatzes eines Unternehmens in Abhängigkeit von Werbeausgaben und Marktbedingungen.

Algorithmen

- Lineare Regression: Ein einfaches Modell, das eine lineare Beziehung zwischen Eingabe- und Ausgabewerten annimmt.
- Polynomial Regression: Eine Erweiterung der linearen Regression, die nichtlineare Beziehungen modelliert.
- Support Vector Regression (SVR): Eine Variante der SVM, die für kontinuierliche Ausgabewerte verwendet wird.
- Entscheidungsbaumregression: Ein Modell, das die Daten in kontinuierliche Intervalle aufteilt und Vorhersagen trifft.
- Neuronale Netze: Auch für Regressionsaufgaben anwendbar, insbesondere bei komplexen und nichtlinearen Datenbeziehungen.

Bewertung

Die Leistung wird üblicherweise mit Metriken wie dem mittleren absoluten Fehler (MAE), dem mittleren quadratischen Fehler (MSE) und dem Bestimmtheitsmaß (R^2 -Wert) bewertet. Die Unterschiede zwischen Klassifikation und Regression zeigt [Tabelle 2.1](#):

Tabelle 2.1: Dargestellt sind die Unterschiede zwischen Klassifikation und Regression nach ausgewählten Kriterien

Kriterium	Klassifikation	Regression
Ausgabe	Diskrete Klassenlabels	Kontinuierliche Werte
Beispiele	Spam-Erkennung, Bilderkennung	Hauspreisvorhersage, Umsatzprognose
Algorithmen	Logistische Regression, SVM, Entscheidungsbäume, k-NN, Neuronale Netzwerke	Lineare Regression, Polynomial Regression, SVR, Entscheidungsbaumregression, Neuronale Netzwerke
Bewertung	Accuracy, Precision, Recall, F1-Score	MAE, MSE, R^2 -Wert

Klassifikation und Regression sind zwei fundamentale Methoden des überwachten Lernens mit unterschiedlichen Zielen und Anwendungen. Während Klassifikation auf die Zuordnung von Daten zu diskreten Klassen abzielt, konzentriert sich Regression auf die Vorhersage kontinuierlicher Werte. Die Wahl der Methode und des spezifischen Algorithmus hängt von der Art der zu lösenden Problemstellung und den verfügbaren Daten ab. Beide Methoden spielen eine entscheidende Rolle in vielen realen Anwendungen des maschinellen Lernens und der Datenanalyse.

2.1.2 Unüberwachtes Lernen

Im Gegensatz zum überwachten Lernen arbeitet unüberwachtes Lernen mit Daten ohne vorherige Etikettierung. Die Algorithmen suchen nach Strukturen innerhalb der Daten, um Gruppierungen (Clustering), Assoziationen oder die Verteilung in einem Datensatz zu entdecken. Clustering-Verfahren wie K-Means, hierarchisches Clustering und DBSCAN (Ester et al., 1996) sind Beispiele für unüberwachtes Lernen, die dazu dienen, natürliche Gruppierungen innerhalb der Daten zu finden. Ein weiteres Beispiel ist die Hauptkomponentenanalyse (PCA), die dazu verwendet wird, die Dimensionalität von Daten zu reduzieren, indem die Merkmale auf die wichtigsten Komponenten reduziert werden (Tate, 2023). Unüberwachtes Lernen ist besonders nützlich, um Einsichten in Daten zu gewinnen, die sonst nicht offensichtlich wären. Es wird in der Marktsegmentierung, bei der Organisation großer Dokumentensammlungen und in der Genomik verwendet (Hastie et al., 2001).

2.1.3 Verstärkendes Lernen

Verstärkendes Lernen (Reinforcement Learning, RL) ist ein Bereich des maschinellen Lernens, der sich mit der Art und Weise beschäftigt, wie ein Agent in einer Umgebung handeln sollte, um eine Belohnung zu maximieren (R. Sutton & Barto, 1998). Im Gegensatz zu überwachtem und unüberwachtem Lernen, bei denen die Daten vorgegeben sind, interagiert ein RL-Agent mit seiner Umgebung in einem Feedback-Loop, um die optimale Politik für das Erreichen seines Ziels zu lernen. Ein bekanntes Beispiel für RL ist das Training von Computern, um Brettspiele wie Schach oder Go zu spielen, wo der Algorithmus lernt, Züge zu machen, die die Gewinnchancen maximieren (R. S. Sutton & Barto, 2018). RL wird auch in der Robotik für die Navigation und Manipulation, in der Optimierung von Logistiknetzwerken und in personalisierten Empfehlungssystemen eingesetzt.

2.1.4 Deep Learning

Deep Learning ist ein spezielles Feld des maschinellen Lernens, das sich auf Algorithmen konzentriert, die aus mehrschichtigen neuronalen Netzwerken bestehen. Diese tiefen Netzwerke sind in der Lage, komplexe, abstrakte Merkmale aus großen Datenmengen zu extrahieren und zu lernen (LeCun et al., 2015). Deep Learning hat zu bedeutenden Durchbrüchen in der Bild- und Spracherkennung geführt und ist die treibende Kraft hinter vielen modernen KI-Anwendungen, wie selbstfahrenden Autos und effizienteren Suchalgorithmen. Die Architekturen des Deep Learning umfassen Convolutional Neural Networks (CNNs) für die Bildverarbeitung, Recurrent Neural Networks (RNNs) für sequenzielle Daten und Transformer-Modelle, die in der natürlichen Sprachverarbeitung eingesetzt werden (Shiri et al., 2023).

2.2 Ausgewählte traditionelle Klassifikationsalgorithmen

Dieser Teil stellt die Funktionsweisen und mathematischen Definitionen von *Support Vector Machines* und *Random Forest* vor.

2.2.1 Support Vector Machines (SVM)

Support Vector Machines (SVMs) sind eine Klasse von überwachten Lernalgorithmen, die sowohl für Klassifikations- und Regressionsaufgaben verwendet werden können. Die Grundidee der SVMs wurde von V. N. Vapnik (1963) im Rahmen der statistischen Lerntheorie zu Beginn der 60er Jahre entwickelt. Die frühe Version, bekannt als der „Generalized Portrait Algorithm“, war auf lineare Klassifikation beschränkt (V. N. Vapnik, 1963). Im Jahre 1992 stellte Boser et al. (1992) dann den sogenannten Kernel-Trick vor, der es SVMs ermöglichte, nichtlineare Beziehungen zu modellieren. Dieser Schritt war entscheidend für die Popularität von SVMs (Boser et al., 1992). Die theoretischen Grundlagen von SVMs wurden von V. N. Vapnik (1995) in dem 1995 erschienen Buch „The Nature of Statistical Learning Theory“ dargelegt (V. N. Vapnik, 1995). Ab den 2000er Jahren erreichten SVMs aufgrund ihrer hohen Genauigkeit und ihrer Fähigkeit, mit hochdimensionalen Daten umzugehen, eine breite Akzeptanz in der Praxis. Insbesondere die Eignung für eine Binärklassifikation und die gute Unterstützung durch entsprechende Softwarepakete machten SVMs zu einem populären Klassifikator in Bereichen wie z. B. Bild- und Spracherkennung, Bioinformatik und Textklassifikation (Murty & Raghava, 2016).

Ziel einer linearen SVM ist es, eine optimale Trennlinie (Hyperplane) zu finden, die die Datenpunkte zweier Klassen so trennt, dass der Abstand (Margin) zwischen den nächstgelegenen Datenpunkten beider Klassen und der Hyperplane maximiert wird. Diese nächstgelegenen Datenpunkte werden als Support-Vektoren bezeichnet. [Abbildung 2.3](#) zeigt in der linken Abbildung eine lineare Trennung von Datenpunkten. Die rechte Abbildung zeigt die Verwendung der Hyperplane:




Abbildung 2.3: In der linken Abbildung sind mögliche Ebenen bzw. Linien zur Datenseparierung eingefügt während die rechte Abbildung eine Hyperebene mit optimaler Trennung unter Berücksichtigung der nächstgelegenen Datenpunkte darstellt.

Im Kontext der Textklassifikation werden die einzigartigen Wörter eines Textes in Vektoren im n -dimensionalen Raum umgewandelt und bilden die zu trennenden Datenpunkte. Mathematisch lässt sich die Hyperplane wie in [Gleichung \(2.1\)](#) darstellen (Cortes & Vapnik, 1995):

$$\mathbf{w} \cdot \mathbf{x} - b = 0 \quad (2.1)$$

wobei $\mathbf{w}$ der Normalenvektor zur Hyperplane ist und b ein Bias-Term bzw. eine Verschiebung ist. $\mathbf{x}$ ist ein Vektor im n -dimensionalen Raum. Neben der Definition der Hyperebene muss eine Klassenzuordnung entsprechend der [Gleichung \(2.2\)](#) und [Gleichung \(2.3\)](#) erfolgen. Diese wird durch das Vorzeichen des Ausdrucks $\mathbf{w} \cdot \mathbf{x} - b$:

$$\text{Klasse } +1, \quad \text{wenn } \mathbf{w} \cdot \mathbf{x} - b \geq 1 \quad (2.2)$$

$$\text{Klasse } -1, \quad \text{wenn } \mathbf{w} \cdot \mathbf{x} - b \leq -1 \quad (2.3)$$

bestimmt. (Cristianini & Shawe-Taylor, 2000)

Wie bereits beschrieben, ist der Margin der Abstand zwischen der Hyperplane und den nächstgelegenen Datenpunkten beider Klassen. Eine optimale Hyperplane maximiert diesen Abstand. Der Abstand eines Punktes $\mathbf{x}$ zur Hyperplane wird durch $\frac{|\mathbf{w} \cdot \mathbf{x} - b|}{\|\mathbf{w}\|}$ gegeben. Für die Support-Vektoren beträgt dieser Abstand genau 1 (Schölkopf & Smola, 2002).

Um nun die optimale Hyperplane zu finden, kann das Problem als Optimierungsaufgabe wie unter [Gleichung \(2.4\)](#) formuliert werden (V. N. Vapnik, 1998):

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad (2.4)$$

unter den Nebenbedingungen (siehe [Gleichung \(2.5\)](#)) für alle Trainingsdatenpunkte $(\mathbf{x}_i, y_i)$:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i - b) \geq 1 \quad (2.5)$$

wobei $y_i \in \{-1, +1\}$ die Klassenlabels sind.

In der Praxis sind die Daten oft nicht perfekt trennbar. Daher wird eine „weiche“ Margin eingeführt, die eine gewisse Fehlklassifikation zulässt (Cortes & Vapnik, 1995). Dies wird durch Einführen von Slack-Variablen ξ_i und einer Regularisierungsparameter C erreicht, wie unter [Gleichung \(2.6\)](#) definiert:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \quad (2.6)$$

unter den Nebenbedingungen entsprechend [Gleichung \(2.7\)](#):

$$y_i(\mathbf{w} \cdot \mathbf{x}_i - b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (2.7)$$


Hierbei kontrolliert der Parameter C den Kompromiss zwischen der Maximierung des Margins und der Minimierung der Klassifikationsfehler.

Nach dem Training der SVM wird die Entscheidung für einen neuen Datenpunkt $\mathbf{x}$ durch die Signum-Funktion des linearen Modells ([Gleichung \(2.8\)](#)) definiert, getroffen (Cristianini & Shawe-Taylor, 2000):

$$\text{Vorhersage} = \text{sign}(\mathbf{w} \cdot \mathbf{x} - b) \quad (2.8)$$

Die bisherigen Überlegungen beschränken sich auf eine lineare Trennbarkeit von Datenpunkten. Um auch nicht-lineare Daten zu handhaben, greift man auf den sog. Kernel-Trick zurück: Die Hauptidee besteht darin, dass die SVM nicht direkt auf den ursprünglichen Daten arbeitet, sondern auf einer Transformation der Daten in einen höherdimensionalen Raum, in dem die Daten linear trennbar werden. [Abbildung 2.4](#) visualisiert das dahinterliegende Konzept:

A hyperplane in $\mathbb{R}^2$ is a line



A hyperplane in $\mathbb{R}^3$ is a plane




Abbildung 2.4: Abgebildet ist das Kernel-Trick-Konzept zur Trennung von Daten mittels höherdimensionaler Räume. Die linke Abbildung zeigt einen zweidimensionalen Raum, der durch eine Linie getrennt wird. Die rechte Abbildung ermöglicht eine Trennung von Daten durch eine Ebene im 3D-Raum.

Diese Transformation wird durch die in [Gleichung \(2.9\)](#) definierte Funktion ϕ dargestellt: (Schölkopf & Smola, 2002)

$$\phi : \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad m > n \quad (2.9)$$

Anstatt die Transformationsfunktion ϕ explizit zu berechnen, verwendet man eine Kernel-Funktion K , die das Skalarprodukt der transformierten Merkmale berechnet. Die Formel ist in [Gleichung \(2.10\)](#) dargestellt:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle \quad (2.10)$$

Im dualen Problem der SVM werden die Daten nur in Form von Skalarprodukten verwendet. Eine mathematische Beschreibung des dualen Optimierungsproblems ist in [Gleichung \(2.11\)](#) zu finden und lautet:

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \quad (2.11)$$

unter den in [Gleichung \(2.12\)](#) dargestellten Nebenbedingungen:

$$0 \leq \alpha_i \leq C \quad \text{und} \quad \sum_i \alpha_i y_i = 0 \quad (2.12)$$

wobei $K(\mathbf{x}_i, \mathbf{x}_j)$ die Kernel-Funktion ist (V. N. Vapnik, 1998). Eine Kernel-Funktion $K(\mathbf{x}_i, \mathbf{x}_j)$ berechnet das Skalarprodukt der Bilder der Datenpunkte im höherdimensionalen Raum, ohne dass ϕ explizit bekannt sein muss. Gängige Kernel-Funktionen sind (Schölkopf & Smola, 2002):

Lineare Kernel definiert in [Gleichung \(2.13\)](#):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j \quad (2.13)$$

Polynom-Kernel definiert in [Gleichung \(2.14\)](#):

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j + 1)^d \quad (2.14)$$

Radial Basis Function (RBF) bzw. Gauß-Kernel abgebildet in [Gleichung \(2.15\)](#):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right) \quad (2.15)$$

Sigmoid-Kernel definiert in [Gleichung \(2.16\)](#):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\kappa \mathbf{x}_i \cdot \mathbf{x}_j + c) \quad (2.16)$$

Mit dem Kernel-Trick müssen die Datenpunkte nicht explizit in den höherdimensionalen Raum transformiert werden. Stattdessen verwendet man die Kernel-Funktion direkt in der Optimierungsformel. Dies ermöglicht die effiziente Berechnung der SVM-Lösung auch für hochdimensionale oder nicht-lineare Probleme.

2.2.2 Random Forests (RF)

Random Forest wurde Anfang der 2000er Jahre von Breiman ([2001](#)) vorgestellt. Die Methode basiert auf der Idee der Entscheidungsbäume aber sie erweitert diese durch die Kombination vieler Bäume, um die Genauigkeit und Robustheit der Vorhersagen zu erhöhen. Breiman und Cutler erkannten, dass ein einzelner Entscheidungsbaum zwar leicht verständlich und interpretierbar ist, aber oft nicht die beste Vorhersageleistung bietet. Durch die Kombination mehrerer Bäume, wie in [Abbildung 2.5](#) dargestellt, konnten sie jedoch die Vorhersagegenauigkeit deutlich verbessern:




Abbildung 2.5: Aufbau von Random Forest. Abgebildet ist das Schema zur Klassifikation von Daten durch den Random Forest - Algorithmus.

Ein Random Forest besteht aus einer großen Anzahl von Entscheidungsbäumen, die jeweils auf einem zufälligen Teil des Trainingsdatensatzes trainiert werden. Das Konzept beruht auf zwei wesentlichen Prinzipien:

1. Bagging (Bootstrap Aggregating): Bei dieser Technik wird der Trainingsdatensatz mehrfach mit Zurücklegen (d.h., es können einige Datenpunkte mehrfach ausgewählt werden) zufällig ausgewählt, um verschiedene Sub-Datensätze zu erstellen. Jeder Entscheidungsbaum wird auf einem dieser Sub-Datensätze trainiert (Breiman, 1996).

2. Zufällige Merkmalsauswahl: Bei jedem Split eines Baumes wird nicht der beste Split über alle Merkmale hinweg gesucht, sondern nur über eine zufällige Teilmenge der Merkmale. Dies führt zu einer zusätzlichen Diversifikation der Bäume im Wald.

Das Ziel des Random Forest ist es, durch die Aggregation der Vorhersagen vieler verschiedener Entscheidungsbäume eine robustere und genauere Gesamtvorhersage zu erreichen. Jeder Baum trägt eine Stimme zur Klassifizierung oder Regression bei, und die endgültige Vorhersage des Random Forest basiert auf der Mehrheit der Stimmen oder dem Durchschnitt der Vorhersagen aller Bäume.

Mathematisch kann das Verfahren wie folgt beschrieben werden:

Ein einzelner Entscheidungsbaum $h(x, \Theta_k)$ ist eine Funktion, die auf einem Sub-Datensatz Θ_k trainiert wird. Die Zufallsvariable Θ_k repräsentiert die zufällige Auswahl von Trainingsdaten und Merkmalen. Durch das Erstellen von B verschiedenen Trainingsdatensätzen mittels Bootstrapping (Zufallsauswahl mit Zurücklegen) wird eine Sammlung von Entscheidungsbäumen $\{h(x, \Theta_k), k = 1, \dots, B\}$ trainiert. Die Vorhersage des Random Forest $H(x)$ für eine Eingabe x ist dann die Mehrheit der Stimmen (bei Klassifikation) oder der Durchschnitt der Vorhersagen (bei Regression) aller Bäume entsprechend der mathematischen Definition unter [Gleichung \(2.17\)](#) für die Klassifikation und unter [Gleichung \(2.18\)](#) für die Regression (Breiman, 2001):

$$H(x) = \text{majority_vote}\{h(x, \Theta_k), k = 1, \dots, B\} \quad (\text{für Klassifikation}) \quad (2.17)$$

$$H(x) = \frac{1}{B} \sum_{k=1}^B h(x, \Theta_k) \quad (\text{für Regression}) \quad (2.18)$$

Bei jeder Entscheidung in einem Baum wird eine zufällige Teilmenge von m Merkmalen aus den insgesamt M verfügbaren Merkmalen ausgewählt, und der beste Split wird nur innerhalb dieser Teilmenge gesucht. Diese Zufälligkeit trägt zur Reduktion der Korrelationen zwischen den Bäumen bei und verbessert somit die Gesamtleistung des Random Forest. Random Forest bieten eine Reihe von Vorteilen, insbesondere (Hastie et al., 2009):

- **Genauigkeit:** Random Forests bieten in der Regel eine höhere Vorhersagegenauigkeit als einzelne Entscheidungsbäume, da sie die Varianz durch die Kombination mehrerer Bäume reduzieren.
- **Robustheit:** Sie sind robust gegenüber Overfitting, insbesondere wenn eine große Anzahl von Bäumen verwendet wird.
- **Flexibilität:** Random Forests können sowohl für Klassifikations- als auch für Regressionsaufgaben verwendet werden.
- **Handhabung von fehlenden Werten:** Sie können mit fehlenden Daten umgehen, indem sie die fehlenden Werte auf verschiedene Weise ersetzen oder ignorieren.
- **Merkmalsbedeutung:** Sie bieten eine Methode zur Bewertung der Bedeutung verschiedener Merkmale im Modell, was bei der Feature-Selection hilfreich sein kann.

2.3 Textklassifikation

Textklassifikation ist ein fundamentaler Anwendungsbereich des maschinellen Lernens, bei dem Textdokumente automatisch in vordefinierte Kategorien eingeteilt werden. Diese Technik wird in einer Vielzahl von Bereichen eingesetzt, darunter Spam-Erkennung, Themenzuordnung und automatische Tag-Vergabe (Mironczuk & Protasiewicz, 2018). Die Herausforderung bei der Textklassifikation liegt in der Verarbeitung und Umwandlung von unstrukturierten Textdaten in ein Format, das von maschinellen Lernalgorithmen genutzt werden kann.

Der angewandten Methodik liegt das grundsätzliche Schema in [Abbildung 2.6](#) für die Entwicklung eines Machine - Learning - Modells zugrunde:




Abbildung 2.6: Visualisiert ist der prinzipielle Ablauf zur Entwicklung eines Machine - Learning - Modells.

In diesem Fall entspricht der Punkt „Application“, auf der das Modell angewendet wird, keiner industriellen Applikation sondern es erfolgt der Einsatz des finalen Modells auf die bereitgestellten Testdaten.

Die Textklassifikation durchläuft dabei mehrere Schritte (Uysal & Gunal, 2014):

1. **Vorverarbeitung und Feature-Extraktion:** Der erste Schritt in der Textklassifikation ist die Vorverarbeitung der Daten. Dies umfasst das Entfernen von Stopwörtern, die Normalisierung von Text (z.B. durch Stemming oder Lemmatisierung) und die Umwandlung von Text in numerische Features. Traditionelle Methoden der Feature-Extraktion beinhalten Bag-of-Words-Modelle und TF-IDF (Term Frequency-Inverse Document Frequency), die die Häufigkeit und die Wichtigkeit von Wörtern in einem Korpus messen.
2. **Modellierung:** Nach der Vorverarbeitung werden maschinelle Lernalgorithmen angewendet, um Muster in den Daten zu erkennen und eine Klassifikationsentscheidung zu treffen. Überwachtes Lernen ist hierbei die gängigste Methode. Algorithmen wie Naive Bayes, Support Vector Machines und Random Forests wurden traditionell für die Textklassifikation verwendet. Zwischenzeitlich haben Deep-Learning-Modelle, insbesondere solche, die auf neuronalen

Netzwerken basieren, wie Convolutional Neural Networks (CNNs) und Recurrent Neural Networks (RNNs), an Popularität gewonnen. Aktuell werden häufig transformerbasierte Modelle verwendet, wie im folgenden Abschnitt erläutert.

Deep Learning in der Textklassifikation

Deep-Learning-Modelle haben den Vorteil, dass sie komplexe Muster in großen Datenmengen erkennen können und in der Lage sind, Feature-Engineering automatisch durchzuführen. Besonders bemerkenswert sind die Entwicklungen im Bereich der Transformer-Modelle, wie BERT (Bidirectional Encoder Representations from Transformers) (Devlin et al., 2018) und GPT (Generative Pretrained Transformer) (Howard & Ruder, 2018), die neue Maßstäbe in der Textklassifikation gesetzt haben. Diese Modelle nutzen die Kontextualität von Wörtern, indem sie bidirektionale oder sequenzielle Verarbeitung für ein tieferes Verständnis der Textbedeutung einsetzen.

Herausforderungen und zukünftige Richtungen

Trotz der Fortschritte in der Textklassifikation gibt es weiterhin Herausforderungen, wie den Umgang mit ungleich verteilten Daten (Class Imbalance), die Erkennung von Ironie und Sarkasmus und die Verarbeitung von Sprachvariationen und Dialekten. Zudem ist die Erklärbarkeit von Deep-Learning-Modellen ein aktives Forschungsfeld, da diese Modelle oft als „Black Boxes“ angesehen werden (Hassija et al., 2023). Die zukünftige Forschung konzentriert sich auf die Verbesserung der Generalisierbarkeit von Modellen, die Entwicklung von Ansätzen zur Reduzierung von Verzerrungen und die Schaffung von transparenteren und verständlicheren Modellen.

2.4 Evaluation

Bei der Bewertung von Klassifikationsmodellen, wie sie häufig im maschinellen Lernen und in der Datenanalyse eingesetzt werden, ist es unerlässlich, verschiedene Metriken zu verwenden, um die Leistungsfähigkeit der Modelle umfassend zu beurteilen.

2.4.1 Evaluationsmetriken

Zu den gängigsten Evaluationsmetriken gehören Accuracy, Precision, Recall, F1-Score und Macro-F1-Score. Diese Metriken basieren auf der Konfusionsmatrix, die eine detaillierte Übersicht über die Vorhersagen eines Modells bietet (Zhou & Liu, 2021).

Konfusionsmatrix

Die Konfusionsmatrix ist eine spezielle Tabelle, die die Leistung eines Klassifikationsmodells darstellt. Für ein binäres Klassifikationsproblem kann sie wie folgt dargestellt werden:

		Vorhergesagte Klasse	
		Positiv	Negativ
Tatsächliche Klasse	Positiv	TP	FN
	Negativ	FP	TN

TP (True Positives): Anzahl der richtig als positiv klassifizierten positiven Beispiele.

FN (False Negatives): Anzahl der fälschlicherweise als negativ klassifizierten positiven Beispiele.

FP (False Positives): Anzahl der fälschlicherweise als positiv klassifizierten negativen Beispiele.

TN (True Negatives): Anzahl der richtig als negativ klassifizierten negativen Beispiele.

Accuracy

Die Accuracy ist dargestellt unter [Gleichung \(2.19\)](#) und bildet das Verhältnis der korrekt klassifizierten Instanzen zur Gesamtanzahl der Instanzen ab:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.19)$$

Accuracy ist eine einfache und intuitive Metrik, die jedoch bei unausgewogenen Datensätzen irreführend sein kann.

Precision

Precision ist der Anteil der korrekt vorhergesagten positiven Beobachtungen zu allen vorhergesagten positiven Beobachtungen, wie unter [Gleichung \(2.20\)](#) beschrieben:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.20)$$

Precision misst die Genauigkeit der positiven Vorhersagen eines Modells und ist besonders nützlich, wenn die Kosten für False Positives hoch sind.

Recall

Recall, auch als Sensitivität oder True Positive Rate bekannt, ist der Anteil der korrekt vorhergesagten positiven Beobachtungen zu allen tatsächlichen positiven Beobachtungen. Die Formel findet sich unter [Gleichung \(2.21\)](#):

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.21)$$

Recall ist eine wichtige Metrik, wenn es darauf ankommt, möglichst alle positiven Fälle zu erkennen, insbesondere wenn die Kosten für False Negatives hoch sind.

F1-Score

Der F1-Score ist das harmonische Mittel von Precision und Recall und unter [Gleichung \(2.22\)](#) definiert. Er bietet einen ausgewogenen Kompromiss zwischen diesen beiden Metriken und wird verwendet, wenn sowohl Precision als auch Recall wichtig sind:

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.22)$$

Der F1-Score erreicht seinen höchsten Wert bei 1 (perfekte Precision und Recall) und seinen niedrigsten Wert bei 0.

Macro-F1-Score

Der Macro-F1-Score ist der Durchschnitt der F1-Scores für jede Klasse und behandelt jede Klasse gleich, unabhängig von ihrer Häufigkeit. Er wird berechnet, indem die F1-Scores jeder Klasse summiert und dann durch die Anzahl der Klassen geteilt werden. Eine Darstellung ist in [Gleichung \(2.23\)](#) zu finden.

$$\text{Macro-F1-Score} = \frac{1}{N} \sum_{i=1}^N \text{F1-Score}_i \quad (2.23)$$

Hierbei ist N die Anzahl der Klassen. Der Macro-F1-Score ist besonders nützlich, wenn die Klassen unausgewogen sind, da er die Leistung über alle Klassen hinweg gleich gewichtet.

Evaluationsmetriken wie Accuracy, Precision, Recall, F1-Score und Macro-F1-Score bieten umfassende Einblicke in die Leistungsfähigkeit von Klassifikationsmodellen. Sie helfen, die Stärken und Schwächen eines Modells zu identifizieren und zu verstehen, wie gut es bei der Erkennung und Klassifizierung von Daten arbeitet. Die Auswahl der richtigen Metriken hängt in der Regel von den spezifischen Anforderungen und Zielen des Klassifikationsproblems ab.

2.4.2 Cross-Validation

Cross-Validation ist eine wesentliche Technik zur Bewertung der Generalisierungsfähigkeit eines Modells. Sie bietet eine robuste Methode, um die Leistung eines Modells zu messen, indem sie das gesamte verfügbare Datenmaterial effizient nutzt. Im Folgenden werden die Grundlagen und spezifische Formen wie 5-fach und 10-fach Cross-Validation detailliert erläutert (Zhou & Liu, 2021).

Grundlagen der Cross-Validation

Cross-Validation teilt den Datensatz in mehrere Teile und verwendet verschiedene Kombinationen dieser Teile, um ein Modell zu trainieren und zu testen. Diese Technik hilft, die Verzerrungen zu reduzieren, die bei einer einzigen Teilung in Trainings- und Testdaten auftreten können und bietet eine zuverlässigere Schätzung der Modellleistung.

Der am häufigsten verwendete Ansatz ist die k -fache Cross-Validation, wobei k die Anzahl der Teile oder Folds darstellt. Der gesamte Datensatz wird in k gleich große Teile aufgeteilt. Das Modell wird k -mal trainiert und getestet, wobei jedes Mal ein anderer Teil als Testdaten verwendet wird und die restlichen $k - 1$ Teile zum Training genutzt werden. Der Prozess lässt sich wie folgt zusammenfassen:

1. Teile den Datensatz in k gleich große Folds.
2. Trainiere das Modell k Mal, jedes Mal mit $k - 1$ Folds als Trainingsdaten und einem Fold als Testdaten.
3. Aggregiere die Leistungsmetriken aus jedem Fold, um eine durchschnittliche Leistungsmessung zu erhalten.

Formeln für Cross-Validation

Die durchschnittliche Leistung einer Metrik, z. B. Accuracy, Precision, Recall oder F1-Score, wird über alle Folds hinweg berechnet. Sei M die gewählte Metrik und M_i der Wert der Metrik im i -ten Fold, siehe dazu [Gleichung \(2.24\)](#)

$$\text{Mittelwert der Metrik} = \frac{1}{k} \sum_{i=1}^k M_i \quad (2.24)$$

Diese Mittelung reduziert die Varianz der Leistungsbewertung und bietet eine stabilere Schätzung der Modellleistung.

5- und 10-fache Cross-Validation

Bei der 5-fachen Cross-Validation ([Gleichung \(2.25\)](#)) wird der Datensatz in fünf Teile aufgeteilt. Das Modell wird fünfmal trainiert und getestet, wobei jedes Mal ein anderer Teil als Testdaten verwendet wird. Dieser Ansatz ist ein guter Kompromiss zwischen Berechnungsaufwand und Stabilität der

Schätzung.

$$\text{Mittelwert der Metrik} = \frac{1}{5} \sum_{i=1}^5 M_i \quad (2.25)$$

Die 10-fache Cross-Validation ([Gleichung \(2.26\)](#)) teilt den Datensatz in zehn Teile und trainiert das Modell zehnmal. Diese Methode bietet eine noch stabilere Schätzung der Modelleistung, da mehr Folds verwendet werden um die Varianz zu reduzieren. Das ist aber mit einem höheren Rechenaufwand verbunden.

$$\text{Mittelwert der Metrik} = \frac{1}{10} \sum_{i=1}^{10} M_i \quad (2.26)$$

Vorteile der Cross-Validation Die Cross-Validation bietet eine Reihe von Vorteilen (Arif, [2023](#)):

1. **Effiziente Nutzung der Daten:** Da jeder Datenpunkt in einem Fold sowohl zum Training als auch zum Testen verwendet wird, nutzt Cross-Validation die verfügbaren Daten effizient aus.
2. **Stabilität der Leistungsschätzung:** Durch die Mittelung der Ergebnisse mehrerer Folds wird die Varianz der Leistungsschätzung reduziert, was zu robusteren und verlässlicheren Ergebnissen führt.
3. **Reduzierung von Overfitting:** Cross-Validation hilft, Modelle zu identifizieren, die auf den Trainingsdaten überanpassen indem sie ihre Leistung auf verschiedenen Teilmengen der Daten testen.

Cross-Validation ist eine unverzichtbare Technik zur Bewertung von Klassifikationsmodellen. Durch die Anwendung von k-facher Cross-Validation, insbesondere 5-facher oder 10-facher Cross-Validation, kann die Generalisierungsfähigkeit eines Modells zuverlässig geschätzt werden und es wird zusätzlich sichergestellt, dass die Ergebnisse nicht durch zufällige Variationen in den Daten verzerrt werden. Die Wahl der Anzahl der Folds hängt von der Größe des Datensatzes und dem verfügbaren Rechenressourcen ab, wobei höhere Werte von k in der Regel zu stabileren und verlässlicheren Schätzungen führen.

2.5 Definition von Sexismus und seine Formen

Sexismus, d. h. Diskriminierung von Menschen aufgrund ihres Geschlechts, ist auf öffentlichen Kommunikationsplattformen wie sozialen Medien oder den Kommentarbereichen von Nachrichtenmagazinen weit verbreitet (Park et al., [2023](#)). Menschen haben die Möglichkeit, Benutzerkonten unter verschiedenen Namen einzurichten und anonym Kommentare zu hinterlassen. Während diese Meinungsfreiheit einerseits als wertvoll angesehen werden kann, besteht andererseits die Gefahr, dass unter dem Schutz der Anonymität Hasskommentare gepostet und verbreitet werden (Fox et al., [2015](#)). In Kombination mit der großen Anzahl an Beiträgen stellt dies besondere Herausforderungen für Plattformbetreiber und Moderatoren dar, solche Nachrichten zu identifizieren und gegebenenfalls zu entfernen. Der Bedarf an einer Entfernung liegt nicht nur im Ermessen des Betreibers, sondern wird zunehmend aktiv von normativen Institutionen gefordert (Commission, [2016](#)). Es sollte berücksichtigt werden, dass Sexismus nicht immer explizit ausgedrückt wird, sondern häufig in paraphrasierter, ironischer oder anderweitig diffuser Form auftritt (Swim et al., [2004](#)).

Studien haben gezeigt, dass es für Frauen schwer ist, gegen sexistische, frauenfeindliche oder belästigende Sprache auf Online-Plattformen vorzugehen (Wippermann, [2022](#)). Das ist selbst dann der Fall, wenn entsprechende Rechtsmittel theoretisch genutzt werden könnten. In der Praxis treten diverse Hürden auf, die eine Verfolgung erschweren. Das ist neben der Anonymität der Nutzer

häufig ein Mangel an Fachwissen und Ressourcen zur Verfolgung (Marwick & Miller, 2014). Die Kommunikation in Incel-Foren² ist regelmäßig Untersuchungsgegenstand. 2019 wurde eine Studie zu dem Online-Forum *Incel.s.me* durchgeführt, die die Gruppendynamik und den Sprachgebrauch der dort aktiven User untersuchte. Zusätzlich stellten die Organisatoren ein Deep Learning System vor, das die Verwendung von Misogynie, Homophobie und Rassismus mit einer Genauigkeit von 95 % detektieren konnte (Jaki et al., 2019). Eine ähnliche Zielsetzung verfolgt Pelzer et al. (2021) in seiner Studie über Incel-Communities und deren Strukturen (Pelzer et al., 2021). Das sind Bereiche, die im großen Maße von Misogynie geprägt sind und deren Teilnehmer die Ursache Ihrer Probleme Frauen zuordnen.

Incel-Foren sind im Allgemeinen öffentlich zugänglich, sprechen aber eine konkrete, selektive Art von Nutzern an und nicht den durchschnittlichen Nutzer. Daher werden nachfolgend Studien untersucht, die sich mit Hate-Speech und Sexismus auf bekannten und weit verbreiteten Plattformen konzentrieren.

Bei der Definition von Hate-Speech ist nach Mohseni (2021) der Aspekt der Diskriminierung vorhanden, wobei sexistische Hassrede als geschlechterspezifische Hassrede bewertet werden kann (Mohseni, 2021). Daher wird Sexismus als Teilbereich von sog. Hate-Speech oder offensiver Sprache betrachtet. Für diesen Themenkomplex, der sämtliche herabsetzende, beleidigende oder ähnlich diskriminierende Sprache im Kontext von Online-Medien zusammenfasst, liegen differenzierte Forschungen vor.

Eine aufschlussreiche Studie aus Spanien aus dem Jahr 2016 untersuchte 460 unaufgeforderte Kommentare zu vier Videos auf YouTube. (Bou-Franch & Blitvich, 2016) Die Videos wurden zur Positionierung gegen den Missbrauch von Frauen veröffentlicht. Die Studie kam zu dem Ergebnis, dass in den Kommentaren drei Strategien des Missbrauchs angewendet wurden:

1. Die Verharmlosung des Missbrauchs
2. Die Leugnung der Existenz des Missbrauchs
3. Die Beschuldigung von Frauen

Ein Zusammenhang dieser Strategien entsteht auf Mikroebene durch Interaktion, in der die eigene Gruppe positiv und die andere Gruppe entsprechend negativ dargestellt wird. Eine differenzierte Betrachtung dieser drei Strategien ermöglicht die Aufteilung in verschiedene Formen von Sexismus, die online auftreten (Bou-Franch & Blitvich, 2016):

1. **Direkte Beleidigungen und Herabwürdigungen:** Diese beinhalten abwertende oder erniedrigende Kommentare, die sich gezielt gegen das Geschlecht einer Person richten.
2. **Sexuelle Belästigung:** Unangemessene und unerwünschte sexuelle Kommentare, Anspielungen oder Aufforderungen.
3. **Geschlechterstereotype:** Verallgemeinerungen und Vorurteile, die auf stereotypischen Vorstellungen basieren, wie zum Beispiel die Annahme, dass Frauen weniger kompetent in bestimmten Bereichen sind.
4. **Victim Blaming:** Kommentare, die Opfern von Belästigung oder Gewalt die Schuld geben, oft mit der Begründung, sie hätten sich anders verhalten oder gekleidet.
5. **Gaslighting:** Manipulative Kommentare, die darauf abzielen, die Wahrnehmung oder das Selbstbewusstsein von Frauen zu untergraben und sie an ihrer eigenen Realität zweifeln zu lassen.

²Incel als Kofferwort bestehend aus **in**voluntary und **cel**ibate. Auf deutsch: „unfreiwillig“, „sexuell enthaltsam“

6. **Mansplaining:** Kommentare, bei denen Männer Frauen herablassend erklären, was sie bereits wissen, oft in einem bevormundenden Ton.
7. **Trolling und Cybermobbing:** Systematische Belästigung und Provokation von Frauen mit dem Ziel, sie zu verunsichern oder zum Schweigen zu bringen.
8. **Objektivierung:** Kommentare, die Frauen auf ihr Aussehen oder ihre Sexualität reduzieren, anstatt ihre Fähigkeiten oder Meinungen anzuerkennen.
9. **Verharmlosung oder Leugnung von Sexismus:** Kommentare, die behaupten, Sexismus sei kein echtes Problem oder übertrieben dargestellt, was die Erfahrungen von Betroffenen marginalisiert.
10. **Diskriminierung durch Missachtung:** Ignorieren oder Abwerten von Beiträgen und Meinungen, die von Frauen stammen, oft kombiniert mit einer Bevorzugung männlicher Beiträge.

Die Ausführungen zeigen, dass Sexismus sowohl in seiner Form als auch in der Art des Auftretens vielschichtig und variabel sein kann und daher kein einheitlicher Konsens über eine exakte Definition und Abgrenzung besteht.

Während Sexismus eine geschlechterspezifische Ausprägung aufweist und somit auch gegen Männer gerichtet sein kann, beschreibt der Begriff der Misogynie den tief verwurzelten Hass oder die Abneigung speziell gegen Frauen. Dieser manifestiert sich oft durch diskriminierendes, herabwürdigendes oder feindseliges Verhalten gegenüber Frauen und Mädchen. Eine entsprechende Definition ist im Dictionary (2024) zu finden: Misogyny is defined as „dislike of, contempt for, or ingrained prejudice against women“ (Dictionary, 2024).

2.6 Grundlagen der Sentimentanalyse

Da bei der Featurezusammenstellung zum Training der ML-Modelle ebenfalls Emotionen und die generelle Ausprägung der Texte berücksichtigt wurde, ist eine Erläuterung der Grundlagen der Sentimentanalyse notwendig.

Die Sentimentanalyse, die als Teilbereich des „Opinion Mining“ bekannt ist, gehört zum maschinellen Lernen und der natürlichen Sprachverarbeitung (NLP). Ihr Ziel ist es, die Stimmung oder Meinung hinter einem Text zu identifizieren und zu klassifizieren (Wankhade et al., 2022). Die Anwendungen der Sentimentanalyse sind vielfältig und umfassen:

1. Markenwahrnehmung und Kundenstimmung: Unternehmen nutzen Sentimentanalyse, um die öffentliche Wahrnehmung ihrer Marke zu überwachen und zu verstehen.
2. Produktverbesserung: Kundenfeedback wird analysiert, um Produkte zu verbessern und neue Features zu entwickeln.
3. Kundenservice: Personalisierung des Kundenservice durch Verständnis der Kundenmeinungen.
4. Finanzmarktanalyse: Vorhersage von Aktienmarkttrends basierend auf der öffentlichen Stimmung.
5. Politikanalyse: Analyse von Wahlen und politischen Kampagnen, um die öffentliche Meinung zu politischen Themen zu verstehen (Shathik & Karani, 2020).

Die Erkennung von Sexismus ist eine spezialisierte Rolle, da es nicht nur darum geht, positive oder negative Stimmungen zu erkennen, sondern auch subtile und oft kontextabhängige sexistische Äußerungen zu identifizieren. Für eine Klassifizierung der Stimmungen kann Plutchik's *Rad der Emotionen* verwendet werden, welches in [Abbildung 2.7](#) abgebildet ist (Plutchik, 1980):




Abbildung 2.7: Abgebildet sind die acht Basisemotionen und deren Ausprägungen nach dem Modell von Plutchik. Das Zentrum setzt sich aus den stärksten Emotionen zusammen während die äußeren Kreise schwache Ausprägungen darstellen.

Das Modell zeigt acht Basis-Emotionen: *joy* (Freude), *trust* (Vertrauen), *fear* (Angst), *surprise* (Überraschung), *sadness* (Traurigkeit), *anticipation* (Vorfreude), *anger* (Wut) und *disgust* (Ekel). Je näher die Emotionen in Richtung Zentrum liegen, desto ausgeprägter ist die einzelne Emotion. Entsprechend verringert sich die Intensität bei Positionierung weg vom Zentrum. Die acht Basis-Emotionen sind auch die Merkmale in der unter [Abschnitt 4.3.2](#) durchgeführten Analyse.

Es lassen sich drei Ebenen unterscheiden: Dokumenten-, Satz-, oder Aspekt- bzw. Featureebene (Shathik & Karani, [2020](#)):

- **Sentimentanalyse auf Dokumentenebene:** Hier werden die kompletten Dokumente als positiv oder negativ klassifiziert.
- **Sentimentanalyse auf Satzebene:** Auf der Satzebene wird jeder Satz als subjektiv oder objektiv, und dann in eine positive, negative oder neutrale Klasse kategorisiert.
- **Sentimentanalyse auf Aspekt- oder Featureebene:** Diese Art der Stimmungsklassifizierung befasst sich mit der Identifizierung und Extraktion von Elementmerkmalen aus den Quelldaten.

Eine der größten Herausforderungen in der Sentimentanalyse ist die Erkennung von Ironie, Sarkasmus und kontextabhängigen Bedeutungen. Diese Nuancen erfordern fortschrittliche Algorithmen, die in der Lage sind, über einfache Schlüsselwort-Erkennung hinauszugehen (Siegel & Alexa, [2020](#)).

Techniken und Algorithmen

Traditionelle Ansätze der Sentimentanalyse basieren auf lexikonbasierten Methoden. Diese Techniken verwenden vordefinierte Listen von Wörtern, die mit bestimmten Stimmungen assoziiert sind. Solche Methoden sind jedoch oft limitiert, da sie keine kontextuellen Informationen berücksichtigen können (Siegel & Alexa, [2020](#)). Daher steht die Sentimentanalyse vor mehreren Herausforderungen:

- **Kontextinterpretation:** Das Verständnis des Kontextes, in dem Wörter verwendet werden, ist entscheidend. Ironie und Sarkasmus sind besonders schwer zu erkennen, da sie oft das Gegenteil von dem ausdrücken, was sie wörtlich bedeuten.
- **Mehrdeutigkeit:** Viele Wörter haben mehrere Bedeutungen, und ihre genaue Interpretation hängt vom Kontext ab.

- **Sprachgebrauch und Slang:** Die Vielfalt der Sprache, einschließlich Dialekte, Slang und Neologismen, stellt zusätzliche Herausforderungen dar.

Im Kontext des maschinellen Lernens für die Sentimentanalyse ergeben sich unter anderem zwei weitere wichtige Problematiken:

- **Ungleichmäßige Trainingsdaten:** Verzerrungen in den Trainingsdaten können zu ungenauen Modellen führen. Ein weiterer Aspekt ist die oft ungleichmäßige Verteilung von positiven und negativen Beispielen.
- **Verzerrungen und Bias:** Algorithmen können bestehende gesellschaftliche Verzerrungen widerspiegeln und verstärken, was zu falschen Klassifizierungen führen kann.

2.7 Die Detektion von Sexismus in Texten

Die Detektion von Sexismus ist eine spezialisierte und herausfordernde Aufgabe innerhalb der Sentimentanalyse und des maschinellen Lernens. Es geht darum, sexistische Äußerungen zu identifizieren, die sich gegen eine bestimmte Geschlechtsgruppe richten oder stereotype Ansichten verstärken (Karthikeyan et al., 2023).

Eine der größten Herausforderungen bei der Sexismus-Detektion ist die korrekte Interpretation des Kontexts. Sexistische Sprache kann oft subtil sein und erfordert ein tiefes Verständnis des Kontexts, in dem bestimmte Wörter oder Phrasen verwendet werden (Băroiu & Trăușan-Matu, 2022). Ironie und Sarkasmus können die Erkennung weiter erschweren, da sie buchstäblich das Gegenteil von dem ausdrücken können, was gemeint ist.

Die Vielfalt der Sprache, einschließlich Dialekte, Slang und Neologismen, stellt maschinelle Lernsysteme vor zusätzliche Herausforderungen. Sexistische Ausdrücke können kulturell spezifisch sein und sich im Laufe der Zeit ändern, was eine kontinuierliche Aktualisierung der Erkennungssysteme erfordert (Joshi et al., 2024).

Die Verfügbarkeit von qualitativ hochwertigen, annotierten Datensätzen für das Training von Algorithmen ist eine weitere Herausforderung. Viele Datensätze enthalten Verzerrungen oder sind nicht umfassend genug, um die Vielfalt sexistischer Ausdrücke abzudecken (Beck, 2023). Darüber hinaus ist die manuelle Annotation von Daten subjektiv, was zu Inkonsistenzen in den Trainingsdaten führen kann.

Algorithmen können bestehende gesellschaftliche Verzerrungen widerspiegeln und verstärken, wenn sie mit voreingenommenen Daten trainiert werden (van Niekerk et al., 2024). Dies kann dazu führen, dass bestimmte Gruppen oder Ausdrucksweisen fälschlicherweise als sexistisch oder nicht sexistisch klassifiziert werden.

Zusammenfassend ist zu sagen, dass sich die Sentimentanalyse als ein mächtiges Werkzeug zur Erfassung und Analyse der öffentlichen Meinung etabliert hat. Die Detektion von Sexismus in Texten stellt jedoch eine besondere Herausforderung dar, die weit über die einfache Klassifizierung von Stimmungen hinausgeht. Fortschritte in der NLP und im maschinellen Lernen, zusammen mit einer sorgfältigen Berücksichtigung ethischer und sozialer Aspekte, sind entscheidend, um diese Herausforderungen zu bewältigen und faire, genaue und vertrauenswürdige Systeme zu entwickeln.

3 Verwandte Arbeiten

Dieses Kapitel untersucht die aktuelle Forschung zur Sexismusdetektion, mit besonderem Fokus auf den Algorithmen, die in verschiedenen Aufgaben eine gute Performance erzielten. Diese Aufgaben umfassten typischerweise die Erkennung von Hate Speech, wobei einige spezialisierte Wettbewerbe sich explizit auf die Detektion von Sexismus konzentrierten. Im zweiten Abschnitt dieses Kapitels werden diese spezifischen Aufgaben ausführlich betrachtet.

3.1 Forschungsarbeiten zu Hate-Speech und Sexismusdetektion

Aktuelle Forschungsarbeiten die speziell den Fokus auf Hate-Speech aufgrund der ab 2015 eingesetzten Migrationswellen setzen, sind z. B. bei Makowski (2020) oder Kreis (2017) zu finden. Im Falle von Rechtsextremismus finden sich aktuelle Untersuchungen bei Hoffmann (2020) oder Baumgarten (2017). Auch in dem Bereich des Sexismus sind mehrere Untersuchungen und Forschungen vorgenommen worden, wenn auch nicht in dem Umfang wie zu den Themen Zuwanderung, Politik oder Extremismus.

Die Herausforderungen bei der automatischen Erkennung von Hassrede in Texten sind in den letzten Jahren zunehmend in den Fokus der Forschung gerückt. Zur Zeit von GermEval 2018 waren die am häufigsten verwendeten Klassifikatoren neuronale Netze (Rother & Rettberg, 2018; Xi et al., 2018). Unter den nicht-neuronalen Typen bildeten SVMs die größte Untergruppe, gefolgt von logistischer Regression und Entscheidungsbäumen (Ruppenhofer et al., 2019). Es war zu erkennen, dass klassische, merkmalsbasierte Methoden wie SVMs mit Deep-Learning-Modellen konkurrierten. Dies spiegelt sich auch in den Ergebnissen wider. Neuronale Netze konnten dort gute Ergebnisse erzielen aber traditionelle, überwachende Methoden erreichten ähnliche Ergebnisse (Wiegand et al., 2019). Eine Studie aus dem Jahr 2018 kam zu einem ähnlichen Schluss darüber, welche Algorithmen bis zu diesem Zeitpunkt am häufigsten für die Erkennung von Hassrede in wissenschaftlichen Arbeiten verwendet wurden (Fortuna & Nunes, 2018): Sie zeigt eine Dominanz von Support Vector Machines, gefolgt von Random Forest.

Eine Veränderung ist bereits bei der GermEval 2019 zu erkennen (Struß et al., 2019). Die leistungstärksten Systeme für alle drei Subtasks waren die auf Transformern basierenden Sprachmodelle BERT (Devlin et al., 2018). Es ist auch zu beachten, dass fast ebenso gute Ergebnisse mit SVMs erzielt wurden. Die Kategorie der standardmäßigen Deep-Learning-Architekturen war in den jeweiligen Top-3-Teams nicht vertreten. Diese Verteilung hat sich zugunsten der auf Transformern basierenden Ansätze verschoben, wie ein Blick auf die aktuellen Tasks zeigt.

Neben diesen Ansätzen gab es weitere Bemühungen, Sexismus in Texten zu detektieren. Bei Samory et al. (2021) wurde die Erkennung von Sexismus durch die Nutzung psychologischer Skalen und adversarieller Beispiele untersucht. Verschiedene Dimensionen von Sexismus konnten durch bestehende Skalen operationalisiert werden und wurden verwendet, um bestehende und neue Datensätze zu annotieren. Die Ergebnisse zeigen, dass aktuelle Modelle nur auf einen engen Satz sprachlicher Marker von Sexismus reagieren und Schwierigkeiten haben, auf out-of-domain Beispiele zu generalisieren (Samory et al., 2021). Die Herausforderung, Multilingualität zu berücksichtigen, wurde von Schütz et al. (2022) untersucht. Dabei wurden multilinguale Transformer-Modelle zur automatischen Erkennung von Sexismus in sozialen Medien verwendet. Die Modelle wurden auf einer Vielzahl von Datenquellen vortrainiert und anschließend feingetunt, um die Klassifikationsgenauigkeit zu maximieren. Insbesondere wurden mBERT und XLM-R verwendet (Schütz et al., 2022).

Bei einer menschlichen Klassifizierung von Texten hinsichtlich ihres Ausdrucks von Sexismus handelt es sich bis zu einem gewissen Grad um eine subjektive Wahrnehmung des Annotators. Dies stellt eine besondere Herausforderung für einen Algorithmus dar, der Texte automatisch klassifizieren soll. Dies wird auch bei zukünftigen Herausforderungen von Bedeutung sein, wie z. B.:

In der EXIST-2024 Challenge, die im September 2024 stattfindet. Es werden insgesamt fünf Aufgaben präsentiert (Plaza et al., 2024): Aufgabe 1 umfasst eine binäre Klassifikation, um festzustellen, ob ein Tweet sexistisch oder nicht sexistisch ist. Wenn er als sexistisch eingestuft wird, erfordert Aufgabe 2 die Klassifikation der Absicht des Autors. Aufgabe 3 beinhaltet die Kategorisierung von Sexismus in die folgenden Kategorien: *Ideologische und Ungleichheit*, *Stereotypisierung und Dominanz*, *Objektivierung*, *Sexuelle Gewalt und Frauenfeindlichkeit* und *Nicht-sexuelle Gewalt*. Aufgaben 4 und 5 konzentrieren sich auf die Identifikation von Sexismus in Memes und die Bestimmung der Absicht des Autors.

3.2 Vergleich von Shared Tasks zur Sexismusdetektion

Um einen Überblick über den aktuellen Forschungsstand zur Identifikation und Klassifizierung von Sexismus zu erhalten, wurden ausgewählte Shared Tasks und deren Ergebnisse sowie Methodologien genauer untersucht. Die folgenden Shared Tasks haben sich unter anderem bereits speziell mit der automatischen Erkennung von Sexismus befasst: sEXism Identification in Social networks (EXIST) und Explainable Detection of Online Sexism (EDOS).

IberLEF Shared Task: EXIST (sEXism Identification in Social networks) (Rodríguez-Sánchez et al., 2021)

Es wurden populäre englische und spanische Ausdrücke gesammelt, die die Rolle der Frauen in der Gesellschaft herabsetzen. Diese wurden von Twitter-Konten extrahiert, die solche Phrasen sammeln, und anschließend von Experten analysiert. Der endgültige Satz enthielt über 200 sexistische Ausdrücke. Diese Begriffe wurden verwendet, um mehr als 800.000 Tweets im Zeitraum vom 1. Dezember 2020 bis 28. Februar 2021 zu extrahieren. Seeds mit weniger als 60 Tweets wurden entfernt, sodass der endgültige Satz 94 Seeds für Spanisch und 91 für Englisch umfasste.

Der Subtask von EXIST bei IberLEF 2021 teilte sich in Subtask 1: Binäre Klassifikation, ob Sexismus vorhanden ist oder nicht, und Subtask 2: Feingranulare Klassifizierung der verschiedenen Arten von Sexismus. Der Schwerpunkt der verwendeten Systeme lag auf transformerbasierten Modellen, wie in den Arbeiten von Schütz et al. (2022), de Paula et al. (2021) oder Butt et al. (2021) präsentiert (Butt et al., 2021; de Paula et al., 2021; Schütz et al., 2022). Diese bestanden hauptsächlich aus BERT, multilingualem BERT (mBERT) (Devlin et al., 2018), der spanischen Version von BERT (BETO) (Cañete et al., 2023) oder RoBERTa (Y. Liu et al., 2019). Darüber hinaus verwendeten einige Teams klassische maschinelle Lernmethoden wie Support Vector Machine (SVM) oder Random Forest (RF) (Rodrigo-Ginés et al., 2021). Insbesondere die transformerbasierten Modelle erzielten gute Ergebnisse, wobei die höchsten F1-Scores für Task 1 bei 0.7802 und 0.7797 lagen (Rodríguez-Sánchez et al., 2021). Ein Team verwendete HurtLex (Bassignana et al., 2018), um lexikalische Merkmale zu erzeugen. Sie generierten einen 17-dimensionalen lexikalischen Vektor, um die Häufigkeit jeder Kategorie zu zählen, und konvertierten den lexikalischen Vektor in TF-IDF. Das Ziel war es, die Bedeutung einer Kategorie für einen Text im Korpus zu bestimmen (Jiang & Zubiaga, 2021).

SemEval 2023 mit dem Shared Task 10: Explainable Detection of Online Sexism (EDOS)

Ein großer Teil der Forschung zu Hate-Speech bzw. Sexismus nutzt Twitter-Daten, was zu einem Mangel an Vielfalt bei der Schwere und Form von sexistischen Inhalten führt. Um ein vielfältigeres

Datenset zu erstellen, wurden Daten von Gab und Reddit gesammelt. Gab, eine Plattform für freie (und rechtsextreme) Meinungsäußerung, lieferte 34 Millionen Beiträge (August 2016 bis Oktober 2018), wovon eine Million Beiträge zufällig ausgewählt wurden. Reddit, bekannt für sexistische und antifeministische Gemeinschaften, lieferte Kommentare aus 81 Subreddits. Diese wurden in vier Kategorien eingeteilt: Incels, Men Going Their Own Way, Men's Rights Activists und Pick Up Artists. Es wurden 42 Millionen Kommentare gesammelt und jeweils 250.000 aus jeder Kategorie zufällig ausgewählt (Kirk et al., 2023).

EDOS bot drei Subtasks: Task A für die binäre Klassifikation, ob Sexismus vorhanden ist oder nicht, Task B für die Klassifikation von Sexismus in vier Kategorien und Task C für die feingranulare Einstufung in 11 Vektoren des Sexismus (Kirk et al., 2023). Die höchsten Makro-F1-Scores in Task A wurden von DeBERTa (0.8746) (X. Liu et al., 2020), RoBERTa (0.8740) (Caselli et al., 2021) und ensembled DeBERTa (0.8740) erzielt. In Task B belegte ein befehloptimiertes PaLM-Modell (Chowdhery et al., 2022), das eine parametereffiziente Prompt-Anpassung an die Task-Daten und Mehrheitsvotierung über sechs Iterationen verwendet, den ersten Platz (Kirk et al., 2023). Den ersten Platz in Task C belegte erneut ein vortrainiertes DeBERTa-v3-Modell. Es sollte beachtet werden, dass der Makro-F1-Score für dieses Modell 0.5606 betrug und daher noch Verbesserungsmöglichkeiten bestehen.

Die Literaturübersicht zeigt, dass sowohl traditionelle Algorithmen als auch moderne transformerbasierte Modelle erfolgreich zur Erkennung von Hassrede und Sexismus eingesetzt wurden. Bemerkenswerterweise haben Support Vector Machines (SVMs), Random Forests und Entscheidungsbäume gute Ergebnisse erzielt, die manchmal vergleichbar mit denen neuronaler Netze waren, jedoch mit deutlich geringeren Ressourcenanforderungen. Trotz der Dominanz transformerbasierter Modelle wie BERT und DeBERTa in jüngsten Wettbewerben wie GermEval 2019 und SemEval 2023 zeigen die Ergebnisse, dass klassische Methoden wie SVMs weiterhin wettbewerbsfähig sind und eine ressourceneffiziente Alternative bieten.

3.3 Fazit der Literaturanalyse

Die Analyse der aktuellen Forschung zur Erkennung von Sexismus zeigt, dass traditionelle Algorithmen wie *Support Vector Machines* und *Random Forest* nach wie vor ein erhebliches Potenzial aufweisen. Diese klassischen Methoden haben in mehreren Studien und Wettbewerben, wie GermEval 2019 und SemEval 2023, konkurrenzfähige Ergebnisse erzielt und bieten dabei den Vorteil geringerer Ressourcenanforderungen im Vergleich zu modernen transformerbasierten Modellen wie BERT und DeBERTa.

Ein bemerkenswerter Aspekt, der bisher wenig Beachtung gefunden hat, ist das Problem der unterschiedlichen Meinungen von Annotatoren bei der Klassifizierung von sexistischen Inhalten. Diese Inkonsistenzen stellen eine Herausforderung für die Entwicklung und Bewertung von Algorithmen zur Sexismusdetektion dar und erfordern eine intensivere Forschung, um die subjektiven Wahrnehmungen der Annotatoren besser zu verstehen und in die Modelle zu integrieren.

4 Daten und Methodik

GermEval umfasst eine Reihe von Shared Task Kampagnen, die sich auf die Verarbeitung natürlicher Sprache von deutschsprachigen Texten konzentrieren. Die Ausgabe 2024, „GERMS-DETECT: Sexismus-Erkennung in deutschen Online-Nachrichtenforen“, legte die folgenden Anforderungen fest (Krenn et al., 2024):

Subtask 1 ist eine Binärklassifikation, die bestimmt, ob Texte sexistische bzw. frauenfeindliche Kommentare enthalten oder nicht. Subtask 2 klassifiziert Kommentare feingranular entsprechend den Ausprägungen von Sexismus. Die Möglichkeiten dabei, Texte einzustufen, umfassten folgende fünf Labels (Krenn et al., 2024):

- 0 = Kein Sexismus bzw. Misogynie festgestellt
- 1 = Milder Sexismus/Misogynie
- 2 = Sexismus/Misogynie festgestellt
- 3 = Starker Sexismus/Misogynie
- 4 = Extremer Sexismus/Misogynie

In dieser Arbeit ist ausschließlich der Subtask 1 Untersuchungsgegenstand.

4.1 Beschreibung der Daten

Die Daten wurden als .jsonl-Datei bereitgestellt und bestanden aus deutschen Beiträgen aus dem Kommentarbereich einer österreichischen Online-Zeitung. Eine statistische Beschreibung dieses Datensatzes ist in [Tabelle 4.1](#) zu finden.

Tabelle 4.1: Darstellung verschiedener Charakteristika des Trainingsdatensatzes

Charakteristika	Wert
Anzahl Texte, <i>Sätze</i>	5998
Anzahl Wörter, <i>total</i>	197128
Anzahl Zeichen, <i>total</i>	1297652
Wortlänge, <i>min.</i>	1
Wortlänge, <i>max.</i>	173
Wortlänge, <i>durchschnittlich</i>	32.86

Neben der Wortanzahl wurde eine Gruppierung der Texte anhand der vorkommenden Wortanzahl durchgeführt. [Abbildung 4.1](#) zeigt die Verteilung über die gesamten Trainingsdaten vor Datenvorverarbeitung:




Abbildung 4.1: Abgebildet ist die Verteilung der Wortanzahl je Text über den Korpus.

4.1.1 Explorative Datenanalyse

Für eine genauere Analyse der Zusammensetzung der Texte wurden die verschieden starken Ausprägungen von Sexismus, die auf einer Skala von 1 bis 4 reichten, zu einer gemeinsamen Klasse „Sexismus“ zusammengefasst:

Tabelle 4.2: Dargestellt wird die absolute und relative Anzahl an Kommentaren, die als nicht sexistisch (Klasse 0) bzw. als sexistisch (Klassen 1-4) gelabelt waren.

Label	Anzahl, absolut	Verteilung in Prozent
0	19237	65.95
1,2,3 oder 4	9933	34.05
Gesamt	29170	100.00

Die Übersicht zeigt, dass eine Ungleichverteilung in den Daten vorliegt. Zwei Drittel sind als „kein Sexismus“ klassifiziert, während die Summe aller anderen Labels ein Drittel der Daten ausmacht. Dies wird in [Abbildung 4.2](#) nochmals verdeutlicht:




Abbildung 4.2: Veranschaulicht ist die Ungleichverteilung der Label innerhalb der Trainingsdaten.


4.1.2 Annotationsschema von Subtask 1

Dieser Shared Task unterscheidet sich von vorherigen Aufgaben dadurch, dass er die unterschiedlichen Meinungen der Annotatoren berücksichtigt (Krenn et al., 2024). Diese Herausforderung führt zu einem hohen Maß an Komplexität, da die Vielfalt der Annotatorenperspektiven erhebliche Unsicherheit in den Klassifizierungsprozess einbringt. Während frühere Aufgaben wie EXIST und EDOS hauptsächlich auf die binäre oder mehrstufige Klassifizierung von Sexismus fokussiert waren, zielt die aktuelle Aufgabe darauf ab, die unterschiedlichen Perspektiven der Annotatoren zu integrieren und somit eine robustere und differenziertere Erkennung von Sexismus zu ermöglichen.

Um diese Zielsetzung zu erreichen, sind innovative Ansätze zur Handhabung von Unsicherheiten bei der Annotation erforderlich, was möglicherweise zu neuen Erkenntnissen und Methoden in der automatisierten Textklassifikation führen könnte. Die Besonderheit bei der Einstufung von Texten in Subtask 1 besteht daher in der Anwendung verschiedener Strategien, die die Varianz der Annotatoren berücksichtigen sollten.

4.1.2.1 Ungleichverteilung der Label

Die [Abbildung 4.3a](#) zeigt in Bezug auf das Einstufungsverhalten der einzelnen Annotatoren ebenfalls deutliche Unterschiede. Das betrifft nicht nur die Einstufung als solches sondern auch den Umfang der vorgenommenen Klassifikationen, wie unter [Abbildung 4.3b](#) ersichtlich:



(a) Die Abbildung zeigt das Annotationsverhalten aller zehn Annotatoren für den Korpus.

(b) Dargestellt ist die Anzahl von Annotationen pro Text mit dem Ergebnis, dass der überwiegende Anteil vier bzw. fünf Bewertungen erhalten hat.

Abbildung 4.3: Überblick über die Ungleichverteilung der Label

Drei Annotatoren (A002, A010 und A012) haben fast alle vorliegenden Texte klassifiziert, ein weiterer Annotator knapp 3000 Texte und somit ungefähr die Hälfte. Alle anderen Annotatoren haben deutlich weniger Texte bewertet. 4872 Texte und somit 81,23 % des gesamten Korpus wurden von fünf Personen bewertet, weitere 1073 Texte und somit 17.89 % des Korpus von vier Personen. Über 99 % der Texte haben also eine Bewertung von vier oder fünf Annotatoren erhalten obwohl insgesamt zehn Personen zur Verfügung standen. Das erschwert die Bewertung, ob ein Text als sexistisch oder nicht eingestuft werden soll.

4.1.2.2 Varianz in den Klassifikationen

Neben dieser unausgeglichene Verteilung der Label kommt noch eine ausgeprägte Variation der Label bezogen auf die einzelnen Sätze hinzu. Beispielhaft sollen drei Texte aufgezeigt werden, bei denen die Einstufungen deutlich unterschiedlich waren und kaum Konsens über den Grad des Sexismus besteht. [Tabelle 4.3](#) fasst die Informationen des Beispiel 1 zusammen:

Tabelle 4.3: Abgebildet ist das Beispiel 1 für eine Textannotation (Zeile 27)

Textposition:	27
Text:	"Was ist das für weißes Zeug auf deinem Ding? Aspirin gegen deine Kopfschmerzen. Willst du es oral einnehmen oder als Zäpfchen?"
Anzahl an Annotatoren:	10 / 10
Anzahl verschiedene Label:	3 / 5
Vorkommen der Label:	0 = 5 x 3 = 2 x 4 = 3 x

In diesem Beispiel haben alle Annotatoren den Text gelabelt. Es wurden dabei drei der fünf Label vergeben. Bemerkenswert ist die Tatsache, dass fünf Annotatoren keinen Sexismus festgestellt haben, jedoch drei Annotatoren den Text als extrem sexistisch einstufen.

[Tabelle 4.4](#) führt die Daten zu Beispiel 2 auf:

Tabelle 4.4: Abgebildet ist das Beispiel 2 für eine Textannotation (Zeile 85)

Textposition:	85
Text:	Die französische Revulvation [sic]: alle Schwänze unter die Guillotine!
Anzahl an Annotatoren:	5 / 10
Anzahl verschiedene Label:	3 / 5
Vorkommen der Label:	1 = 1 x 2 = 2 x 4 = 2 x

Die Anzahl der tatsächlichen Label umfasst nur 5 von 10 möglichen Annotatoren. Auch bei dieser geringen Anzahl schwankt die Klassifikation deutlich. Einmal wurde das Label „geringer Sexismus“ vergeben während zwei Annotatoren den Text als extrem sexistisch einstufen.

Ein drittes und abschließendes Beispiel ist in [Tabelle 4.5](#) zusammengefasst:

Tabelle 4.5: Abgebildet ist das Beispiel 3 für eine Textannotation (Zeile 99)

Textposition:	99
Text:	Ich kannte da mal so eine Wasserstoff-Blondine, die war kriminell schoarf [sic]! ;-)
Anzahl an Annotatoren:	5 / 10
Anzahl verschiedene Label:	4 / 5
Vorkommen der Label:	1 = 1 x 2 = 1 x 3 = 2 x 4 = 1 x

Wie im zweiten Beispiel ist auch bei diesem Text die Anzahl der Bewertungen mit fünf eher gering. In diesem Fall sind fast alle Labels vertreten, wobei Texte sowohl als „gering sexistisch“ als auch als „extrem sexistisch“ bewertet wurden.

Insgesamt bestätigen diese Ergebnisse die unter [Abschnitt 2.5](#) festgestellten Herausforderungen, insbesondere die Subjektivität bei den Bewertungen und die Tatsache, dass Sexismus nicht immer eindeutig definiert werden kann. Um diese Variabilität bei der Modellentwicklung und dem Training zu berücksichtigen, wurden innerhalb des Subtask 1 insgesamt fünf verschiedene Strategien zur Bestimmung der Labels verfolgt. In den folgenden Tabellen, die die einzelnen Strategien erläutern, sind die Anzahl an Annotatoren, die einen Text als sexistisch eingestuft haben, mit n_1 dargestellt. Dabei ist unerheblich, welche Ausprägung der Sexismus hat. Das Label kann sowohl aus 1, 2, 3 oder 4 bestehen. Die Anzahl an Annotatoren, die einen Text als nicht sexistisch bewertet haben sind mit n_0 gekennzeichnet.

4.1.2.3 Strategie 1: bin_maj

Die Vorhersage ist 1, wenn die Mehrheit der Annotatoren ein Label ungleich 0 zugewiesen hat. Die Vorhersage ist 0, wenn die Mehrheit der Annotatoren das Label 0 zugewiesen hat. Wenn keine Mehrheit vorhanden ist, werden sowohl das Label 1 als auch das Label 0 bei der Bewertung als korrekt gezählt. Zusammengefasst in [Tabelle 4.6](#):

Tabelle 4.6: Erläuterungen der Labelklassifikation bei Mehrheitsvotierung.

Bewertung der Annotatoren	Mehrheitliches Label	Vorhersage
$n_1 > n_0$	ungleich 0	1
$n_0 > n_1$	0	0
$n_1 = n_0$	-	1 und 0

4.1.2.4 Strategie 2: bin_one

Die Vorhersage ist 1, wenn mindestens ein Annotator ein Label ungleich 0 zugewiesen hat. Andernfalls ist die Vorhersage 0. Zusammengefasst in [Tabelle 4.7](#):

Tabelle 4.7: Darstellung der Labelklassifikation bei mindestens einem Annotator mit der Einstufung: „sexistisch“.

Bewertung der Annotatoren	Bedingung	Vorhersage
$n_1 \geq 1$	Mindestens ein Label ungleich 0	1
$n_1 = 0$	Alle Labels sind 0	0

4.1.2.5 Strategie 3: bin_all

Die Vorhersage ist 1, wenn alle Annotatoren ein Label ungleich 0 zugewiesen haben. Andernfalls ist die Vorhersage 0. Zusammengefasst in [Tabelle 4.8](#):

Tabelle 4.8: Darstellung der Labelklassifikation wenn alle Annotatoren den Text als sexistisch eingestuft haben.

Bewertung der Annotatoren	Bedingung	Vorhersage
$n_1 = n$	Alle Labels ungleich 0	1
$n_1 < n$	Mindestens ein Label ist 0	0

4.1.2.6 Strategie 4: multi_maj

Es erfolgt die Vorhersage des Mehrheitslabels, falls es vorhanden ist. Wenn kein Mehrheitslabel existiert, wird jedes der zugewiesenen Labels bei der Bewertung als korrekte Vorhersage gezählt. Zusammengefasst in [Tabelle 4.9](#):

Tabelle 4.9: Darstellung der Labelklassifikation bei Mehrheitsbildung.

Bedingung	Mehrheitliches Label	Vorhersage
Mehrheit existiert	Label mit Mehrheit	Mehrheitslabel
Keine Mehrheit	-	Jedes zugewiesene Label

4.1.2.7 Strategie 5: disagree_bin

Die Vorhersage ist 1, wenn Uneinigkeit zwischen den Annotatoren über 0 versus alle anderen Labels besteht. Andernfalls ist die Vorhersage 0. Zusammengefasst in [Tabelle 4.10](#):

Tabelle 4.10: Labelklassifikation bei Uneinigkeit zwischen den Annotatoren

Bedingung	Uneinigkeit	Vorhersage
Uneinigkeit vorhanden	Uneinigkeit über 0 und andere Labels	1
Keine Uneinigkeit	-	0

Vor dem Training wurden die Label entsprechend dieser Strategien transformiert, d.h. z.B. für die Strategie „bin_maj“ wurde einem Text des Trainingsdatensatzes das Label 1 zugewiesen, wenn die Mehrheit der Annotatoren diesen als sexistisch (unabhängig von der Ausprägung) gelabelt hat, ansonsten 0. Anschließend wurde für jede Strategie ein Klassifikationsmodell trainiert und eine Vorhersage entsprechend der gewählten Strategie für die Testdaten getroffen.

4.2 Vorverarbeitung

Die folgenden Vorbereitungen wurden für alle Ansätze durchgeführt:

- Vorverarbeitung der Texte, einschließlich der Entfernung von Stoppwörtern.
- Lemmatisierung der Tokens mit TreeTagger (Schmid, 1994).
- Emotionenanalyse mit dem syuzhet-Paket (Mohammad & Turney, 2013).
- TF-IDF

Support Vector Machine (SVM) und Random Forest (RF) wurden für das Modelltraining verglichen. Für jedes Szenario (z.B. bin_maj oder disagree_bin) wurden die Modelle separat trainiert. Zunächst wurden die Vorverarbeitungsschritte für den Trainings- und Testdatensatz durchgeführt. Dies umfasste die Umwandlung der Annotationen in numerische Werte und die Bereinigung der Beiträge. Die Beiträge wurden in Kleinbuchstaben umgewandelt, und redundante Leerzeichen, Satzzeichen und Zahlen wurden entfernt. URLs, Steuerzeichen, Sonderzeichen und Stoppwörter wurden ebenfalls entfernt. Die Liste der Stoppwörter bestand aus der von Diaz et al. (2020) bereitgestellten Liste (Diaz et al., 2020) sowie dem G 8-Wörterbuch (G & Oppenlaender, 2016). Der so bereinigte Korpus wurde tokenisiert und bildete die Grundlage für die weitere Verarbeitung. Um die Vorbereitung für das Training der SVM- und RF-Modelle weiter zu unterstützen, wurde eine zusätzliche Lemmatisierung der vorhandenen Tokens durchgeführt. Hierfür wurde das Tool „TreeTagger“ (Schmid, 1994, 1995) verwendet. Nach der Überprüfung der Ergebnisse mussten zusätzliche Korrekturen vorgenommen werden, einschließlich einer separaten Umwandlung der Wörter „Frau“, „Frauen“ und „frauen“ in „frau“ sowie einer erneuten Umwandlung aller Tokens in Kleinbuchstaben. Die Tokens des Trainingsdatensatzes wurden dann iterativ durch ihr entsprechendes Lemma ersetzt. Wenn während dieses Prozesses kein Lemma durch „TreeTagger“ bestimmt wurde, blieb das ursprüngliche Token erhalten.

Die Analyse der vorhandenen Trainingsdaten identifizierte wie unter [Abbildung 4.3](#) bereits dargestellt neben der Abstimmungsbreite der Annotatoren eine weitere Problematik: Die Schwankungen bei der Bewertung, ob der jeweilige Text sexistisch ist oder nicht.

Ein möglicher Ansatz, dieses Ungleichgewicht zu berücksichtigen und den Datensatz für das folgende Training vorzubereiten, bestand darin, einerseits mögliche Ausreisser zu identifizieren und zusätzlich eine Strategie zu implementieren, die fehlende Werte handhabt.

4.2.1 Identifikation von Ausreißern

Aufgrund der bereits erwähnten, häufig signifikanten Unterschiede in den Bewertungen der Annotatoren wurde eine Z-Score-Berechnung durchgeführt, um die Klassifizierung zu normalisieren und die Vergleichbarkeit der Ergebnisse zu verbessern (Prabhakaran, 2023).

Der Z-Score, auch Standard-Score genannt, ist ein statistisches Maß, das angibt, wie viele Standardabweichungen ein Wert von seinem Mittelwert entfernt ist. Die Z-Score-Berechnung erfolgt in drei Schritten:

1. **Berechnung des Mittelwerts (μ):** Der Mittelwert der Bewertungen für jeden Annotator wird berechnet.
2. **Berechnung der Standardabweichung (σ):** Die Standardabweichung der Bewertungen für jeden Annotator wird berechnet.
3. **Berechnung des Z-Scores (z):** Der Z-Score für jede Bewertung wird wie folgt berechnet:

$$z = \frac{X - \mu}{\sigma} \quad (4.1)$$

Dabei ist:

- X der ursprüngliche Wert (Bewertung) des Annotators,
- μ der Mittelwert der Bewertungen des Annotators,
- σ die Standardabweichung der Bewertungen des Annotators.

Das Verfahren der Z-Score-Berechnung hat dabei mehrere Vorteile:

1. **Standardisierung der Daten:** Durch die Z-Score-Berechnung werden die Bewertungen standardisiert, was bedeutet, dass sie in Einheiten der Standardabweichung ausgedrückt werden. Dies erleichtert den Vergleich von Bewertungen verschiedener Annotatoren, die möglicherweise unterschiedliche Bewertungsmaßstäbe oder -tendenzen haben (Cabello-Solorzano et al., 2023).
2. **Identifikation von Ausreißern:** Z-Scores ermöglichen die einfache Identifikation von Ausreißern, da Bewertungen, die weit vom Mittelwert entfernt sind, durch hohe positive oder negative Z-Scores hervorgehoben werden (Feldman, 2023).
3. **Normalverteilung:** Die Verwendung von Z-Scores ist besonders nützlich, wenn die Daten annähernd normalverteilt sind, da dies die Anwendung vieler statistischer Tests und Verfahren erleichtert (Coll, 2020).

Die Nachteile der Z-Score-Berechnung ³ können in der vorliegenden Situation akzeptiert werden und haben keinen signifikanten Einfluss auf die Analyse der Ergebnisse. Erste Experimente mit der Z-Score - Berechnung auf einen separaten Trainingsdatensatz und einem Schwellwert von 2.5 brachten jedoch nur beschränkt verwendbare Ergebnisse. Auf 4486 Texte wurden insgesamt zwei Ausreißer identifiziert. Eine manuelle Sichtung der Annotationen ließ einen anderen Eindruck über den Umfang vermuten. Eine erste Vermutung für die geringe Identifikation war ein ungünstig gewählter Schwellwert.

Typischerweise wird ein Z-Score-Schwellwert von $\pm 1,96$ verwendet, um statistische Signifikanz zu bestimmen (Cohen, 1988). Dieser Wert entspricht einem Signifikanzniveau von 5% (p-Wert von

³Zum Beispiel die Erfordernis der annähernden Normalverteilung der Bewertungen, schlechtere Interpretation der Ergebnisse oder die Sensitivität gegenüber Ausreißern

0,05) in einer zweiseitigen Hypothesentestung. Das bedeutet, dass die Wahrscheinlichkeit, dass ein Ergebnis durch Zufall außerhalb dieses Bereichs liegt, nur 5% beträgt, was allgemein als akzeptables Niveau für statistische Signifikanz betrachtet wird (Bland & Altman, 1995).

Es sollte daher durch weitere Forschung geprüft werden, inwieweit der Z-Score für eine Identifikation von Ausreißern in diesem Zusammenhang verwendet werden kann. Der Ansatz wurde in der aktuellen Arbeit nicht weiterverfolgt.

4.2.2 Handhabung von fehlenden Werten

Die [Abbildung 4.3b](#) stellte dar, dass eine Vielzahl an Texten von vier oder fünf, nicht jedoch von allen zehn Annotatoren bewertet wurde. Besonders deutlich wird das anhand der [Tabelle 4.11](#):

Tabelle 4.11: Veranschaulicht ist die Anzahl an tatsächlichen Bewertungen je Text über den gesamten Korpus.

Anzahl Bewertungen	1	2	3	4	5	6	7	8	9	10
Anzahl Texte	0	0	0	1073	4872	0	4	0	9	49

Eine Entfernung der fehlenden Werte war nicht zielführend, da es den Datensatz auf einen nicht mehr effizient zu verwendenden Umfang reduzieren würde. Daher wurde der Ansatz verfolgt, die Werte aufzufüllen. Dazu wurde ein Verfahren zur Imputation fehlender Werte in einem Datensatz mittels k-Nearest-Neighbor (k-NN) Imputation verwendet (Murti et al., 2019). Die Imputation wurde mehrfach durchgeführt, um die Genauigkeit zu verbessern, und abschließend durch eine einfache Mittelwert-Imputation ergänzt. Der Workflow setzte sich aus folgenden Schritten zusammen:

1. Vorbereitung der Daten

Zunächst werden aus dem Trainingsdatensatz einige Spalten ausgeschlossen, die nicht für die Imputation benötigt wurden. Anschließend wurden die Daten transponiert, da die k-NN Imputation auf den transponierten Daten durchgeführt werden sollte.

2. k-NN Imputation

Eine Funktion wurde definiert, um die k-NN Imputation auf die transponierten Daten anzuwenden. Diese Funktion funktioniert nach folgendem Schema (Murti et al., 2019):

1. Durchlaufen der Daten: Jede Zelle der transponierten Datenmatrix wird durchlaufen, um fehlende Werte zu identifizieren.
2. Berechnung der euklidischen Distanz: Für jede Zelle mit einem fehlenden Wert wird die euklidische Distanz zu allen anderen Zeilen (im transponierten Datensatz) berechnet.
3. Bestimmung der k nächsten Nachbarn: Die Indizes der k nächsten Nachbarn, die keine fehlenden Werte enthalten, werden bestimmt.
4. Imputation: Der fehlende Wert wird durch den Durchschnitt der entsprechenden Werte der k nächsten Nachbarn ersetzt, falls der Durchschnitt kein fehlender Wert ist.
5. Der Algorithmus wird in mehreren Iterationen ausgeführt, wobei die Anzahl der nächsten Nachbarn (k) in der letzten Iteration reduziert wird, um die Imputation zu verfeinern.
6. Nach der Imputation wurden die Daten zurücktransponiert und auf ganze Zahlen gerundet.

3. Einfache Mittelwert-Imputation Falls nach der k-NN Imputation noch fehlende Werte vorhanden waren, wurde eine einfache Mittelwert-Imputation durchgeführt (Murti et al., 2019). Diese Methode ersetzte fehlende Werte durch den Durchschnitt der vorhandenen Werte in der entsprechenden Spalte.

4. Ergänzung der ursprünglichen Daten Schließlich wurden die imputierten Daten wieder mit den ursprünglichen Spalten ergänzt (Murti et al., 2019). Das Verfahren hatte für die Datenvorbereitung mehrere Vorteile:

- **Erhaltung der Datenstruktur:** Die k-NN Imputation nutzt die Ähnlichkeiten zwischen den Datenpunkten und kann daher die ursprüngliche Struktur und Verteilung der Daten besser erhalten.
- **Flexibilität:** k-NN Imputation kann sowohl numerische als auch kategorische Daten verarbeiten.
- **Mehrfache Anwendungen:** Durch mehrfache Anwendungen und Anpassung von k kann die Genauigkeit der Imputation verbessert werden.

4.3 Feature-Engineering

Das Ergebnis wurde dann zur Merkmalsextraktion mit TF-IDF verwendet. Nach der Reduktion der Sparseness wurden 22 Begriffe für das Training bestimmt. Eine Sentimentanalyse wurde verwendet, um zehn weitere Merkmale zu bestimmen, bestehend aus acht für Emotionen und zwei für die allgemeine Klassifikation in positiv und negativ. Die Ergebnisse der TF-IDF und der Sentimentanalyse wurden kombiniert und als Trainingsmerkmale definiert.

4.3.1 Textrepräsentation durch TF-IDF

TF-IDF (Term Frequency-Inverse Document Frequency) ist eine weit verbreitete Methode in der Textanalyse, um die Wichtigkeit eines Wortes innerhalb eines Dokuments in einer Sammlung von Dokumenten zu bewerten (Ramos, 1999). Der TF-IDF-Algorithmus basiert auf zwei Metriken (Han et al., 2012):

- **Term Frequency (TF):** Dies misst, wie häufig ein Begriff in einem Dokument erscheint. Es wird berechnet als die Anzahl der Vorkommen eines Begriffs im Dokument geteilt durch die Gesamtanzahl der Begriffe im selben Dokument.
- **Inverse Document Frequency (IDF):** Dies misst die Bedeutung eines Begriffs in Bezug auf den gesamten Korpus. Es wird berechnet als der Logarithmus der Gesamtanzahl der Dokumente geteilt durch die Anzahl der Dokumente, die den Begriff enthalten. Damit wird die Häufigkeit eines Begriffs, der in vielen Dokumenten vorkommt, geringer gewichtet.

Die mathematische Definition ist wie folgt (Manning et al., 2008):

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \quad (4.2)$$

wobei:

- $\text{TF}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$ die Termfrequenz ist, also die Anzahl der Vorkommen des Begriffs t im Dokument d dividiert durch die Gesamtanzahl der Begriffe im Dokument d .

- $IDF(t, D) = \log \left(\frac{N}{|\{d \in D : t \in d\}|} \right)$ die Inverse Dokumentfrequenz ist, wobei N die Gesamtanzahl der Dokumente in der Sammlung D und $|\{d \in D : t \in d\}|$ die Anzahl der Dokumente ist, die den Begriff t enthalten.

4.3.2 Sentimentanalyse

Für die folgende Analyse des Korpus bezüglich der vorkommenden Emotionen wurde das NRC Word-Emotion Association Lexikon verwendet (Mohammad & Turney, 2013). Zusätzlich zum NRC-Lexikon gibt es drei weitere Sentiment-Lexika aber das NRC-Lexikon ist das einzige, das nicht-englische Texte verarbeiten kann. Die Analyse ermöglichte eine Klassifikation nach acht verschiedenen Stimmungen: Ärger, Erwartung, Ekel, Angst, Freude, Traurigkeit, Überraschung und Vertrauen. Positive und negative Bewertungen wurden ebenfalls berechnet. Um die Emotion eines gesamten Textes zu bestimmen, wurde für jedes Wort im Text der entsprechende Wert aus dem Lexikon herangezogen. Die Klassifikation erfolgt in einer numerischen Bewertung, wobei ein Wert von 0 bedeutet, dass keine Verbindung zu einer entsprechenden Emotion im Lexikon besteht oder die Wörter unbekannt sind. Je höher der Wert, desto ausgeprägter die Verbindung.

Für jede der acht Grundemotionen sowie die positiven und negativen Bewertungen wurden die individuellen Werte der Wörter summiert. Beispielsweise wurden alle Werte der Wörter, die der Emotion „Ärger“ zugeordnet sind, im Text addiert, um einen Gesamtwert für „Ärger“ zu erhalten. Dasselbe Verfahren wurde für die anderen Emotionen und die positiven bzw. negativen Bewertungen angewendet. Der Ablauf war wie folgt:

1. Wörter analysieren: Jedes Wort im Text wird mit dem Lexikon abgeglichen, um dessen emotionale Wertung zu erhalten.
2. Werte addieren: Die ermittelten Werte für jede Emotion werden für den gesamten Text addiert. So erhält man einen Summenwert für jede der acht Emotionen sowie für die positiven und negativen Bewertungen.
3. Ergebnis interpretieren: Die summierten Werte geben Aufschluss über die vorherrschenden Emotionen und die allgemeine Stimmung des Textes. Höhere Summenwerte in einer bestimmten Kategorie deuten auf eine stärkere Präsenz dieser Emotion oder Stimmung hin.

Nach der Extraktion der Tokens auf Satzebene zeigt [Abbildung 4.4](#) die Verteilungen:




Abbildung 4.4: Abbildung der Verteilung der acht Basisemotionen sowie eine positiv/negativ - Einteilung über den Korpus.

Die Ergebnisse der Sentimentanalyse wurden als zusätzliche Merkmale zum Modelltraining hinzugefügt. Abschließend wurden die Merkmale skaliert.

4.4 Modellauswahl und -training

Aufgrund der in [Kapitel 3](#) festgestellten guten Performance traditioneller Algorithmen in der Textklassifikation wurden für das Training auf die in [Abschnitt 4.1.2](#) beschriebenen Klassifikationsstrategien SVM und RF verwendet. Im ersten Schritt erfolgte eine einfache Performancebestimmung der Modelle durch Training ohne konfigurierte Parameter. Danach erfolgte eine Feinjustierung anhand des in [Abschnitt 4.4.1](#) für SVM und in [Abschnitt 4.4.2](#) für RF beschriebenen Hyperparametertuning.

4.4.1 Hyperparametertuning der Support Vector Machines

Der Prozess begann mit der Festlegung der Trainingskontrolle durch eine 10-fache Kreuzvalidierung, bei der der Datensatz in zehn gleich große Teile aufgeteilt wurde. In jeder Iteration dienten neun Teile dem Training und ein Teil der Validierung des Modells. Diese Methode reduzierte die Gefahr der Überanpassung und stellte sicher, dass das Modell gut generalisierte. Das Support Vector Machine (SVM)-Modell wurde anschließend trainiert. Ein Algorithmus implementierte eine lineare SVM mit gewichteten Klassen. Der Regularisierungsparameter C bestimmte die Komplexität des Modells; ein kleinerer C -Wert führte zu einer stärkeren Regularisierung und einem einfacheren Modell, das weniger anfällig für Überanpassung war. Ein Gewichtungspasparameter passte den Einfluss der verschiedenen Klassen während des Trainings an, was besonders bei unausgewogenen Klassenverteilungen nützlich war, da ein höherer Gewichtungswert die Bedeutung der unterrepräsentierten Klasse erhöhte (Zhang & Zhong, 2020). Eine Skalierung der Daten im Modell wurde nicht

durchgeführt, da dies bereits während der Datenvorbereitung vorgenommen worden war. Durch die Anwendung einer systematischen Grid Search wurden die optimalen Kombinationen der Hyperparameter ermittelt und analysiert. Dieser Ansatz ermöglichte eine umfassende und strukturierte Suche nach den besten Hyperparameterkonfigurationen und trug zur Reduzierung der Überanpassung bei, während die Modellleistung optimiert wurde. Sowohl der Regularisierungsparameter als auch der Gewichtungssparameter spielten hierbei eine entscheidende Rolle. Ein optimaler C -Wert half, ein Gleichgewicht zwischen Bias und Varianz zu finden, während der Gewichtungssparameter die Modellleistung bei unausgewogenen Datensätzen verbesserte.

4.4.2 Hyperparametertuning des Random Forest

Die Trainingskontrolle wurde durch eine 5-fache Kreuzvalidierung festgelegt, wobei der Datensatz in fünf gleich große Teile aufgeteilt wurde. Bei jeder Iteration wurden vier Teile zum Trainieren und ein Teil zur Validierung des Modells verwendet. Diese Methode hatte wie bei SVM den Hintergrund, Überanpassung zu minimieren und die Generalisierungsfähigkeit des Modells zu verbessern wobei die Anzahl an Teile aufgrund von besserer Performance auf fünf Teile beschränkt wurde. Die Anzahl der Features im Trainingsdatensatz wurde durch das Zählen der Spalten im Trainingsdatensatz bestimmt. Diese Information war entscheidend für die Erstellung des Tuning-Rasters, welches die zu testenden Hyperparameterkombinationen definierte. Für die Anzahl der Features bei jedem Split wurden Werte von 1 bis zur Quadratwurzel der Gesamtzahl der Features untersucht. Die Regel zur Auswahl der Splits im Entscheidungsbaum wurde durch spezifische Methoden festgelegt, darunter mathematische Kriterien wie der Gini-Index und zufällige Bäume. Der Gini-Index maß dabei die Ungleichheit einer Verteilung und zielte darauf ab, die Mischungsrate der Klassen in den entstehenden Knoten zu minimieren, wodurch homogene Gruppen entstanden (Breiman et al., 1984). Zufällige Bäume nutzten Zufallssplits, was die Modellvarianz reduzieren konnte und zu robusteren Vorhersagen führte (Breiman, 2001).

Die minimale Anzahl von Beobachtungen in einem Endknoten eines Entscheidungsbaums wurde durch festgelegte Werte bestimmt, die getestet wurden, um die optimale Größe zu finden. Kleinere Endknoten konnten feinere Details erfassen, was jedoch zu Überanpassung führen konnte, während größere Endknoten eine glattere und generalisierbarere Entscheidung ermöglichten. Die Wichtigkeit der Variablen wurde anhand ihres Einflusses auf die Verunreinigung des Modells berechnet. Verunreinigung bezog sich auf die Unreinheit eines Knotens, also wie gemischt die Klassen innerhalb eines Knotens waren. Diese Maßnahme half dabei, die Variablen zu identifizieren, die am stärksten zur Reduktion der Unreinheit beitrugen und somit die wichtigsten Merkmale für das Modell darstellten. Als Algorithmus wurde eine schnelle Implementierung des Random Forest-Algorithmus, der besonders effizient bei großen Datensätzen und vielen Bäumen war, eingesetzt.

5 Ergebnisse und Diskussion

Die Klassifikationsmodelle für den Shared Task der GermEval 2024 wurden während der Wettbewerbsphase auf dem vom GermEval-Organisationskomitee bereitgestellten Trainingsdatensatz trainiert.

5.1 Ergebnisse der SVM

Das [Abschnitt 5.1](#) umfasst in zwei Abschnitten die Ergebnisse zu den Trainings der SVM-Modelle. Der erste Abschnitt stellt die Ergebnisse der Modelle ohne Optimierung vor während der zweite Abschnitt die Ergebnisse nach diversen Feinjustierungen an den Parametern abbildet.

5.1.1 Ergebnisse ohne Hyperparametertuning (SVM)

Jede der fünf Strategien wurde anhand mehrerer Leistungskennzahlen bewertet, darunter F1-Score, Macro-F1, Precision und Recall. Für die Strategie *bin_maj* erzielte das Modell einen F1-Score von 0.8105 und einen Macro-F1 von 0.4150. Die Precision lag bei 0.6826 für die Klasse 0 und bei 0.6333 für die Klasse 1. Der Recall war für die Klasse 0 mit 0.9973 sehr hoch, jedoch für die Klasse 1 sehr niedrig (0.0099). Dies deutet darauf hin, dass das Modell die Klasse 0 fast immer korrekt erkennt, aber Schwierigkeiten hat, die Klasse 1 zu identifizieren.

Die Strategie *bin_one* erreichte einen F1-Score von 0.6812 für die Klasse 0 und 0.5692 für die Klasse 1 sowie den höchsten Macro-F1-Wert von 0.6252. Die Precision und der Recall für diese Strategie waren 0.5749 und 0.7586 für die Klasse 0, bzw. 0.8356 und 0.4555 für die Klasse 1. Diese Werte zeigen eine ausgewogenere Leistung im Vergleich zu *bin_maj*, jedoch gibt es immer noch Raum für Verbesserungen, insbesondere im Bereich des Recalls für die Klasse 1.

Die *bin_all* Strategie erzielte mit einem F1-Score von 0.9124 für die Klasse 0 und 0 für die Klasse 1 die höchste Präzision von 0.8389 für die Klasse 0. Der Macro-F1-Wert lag bei 0.4562, was auf erhebliche Probleme bei der Erkennung der Klasse 1 hinweist. Das Modell erkennt die Klasse 1 überhaupt nicht, was bedeutet, dass alle Instanzen dieser Klasse falsch klassifiziert werden. Dies ist ein gravierendes Problem, das die Nützlichkeit dieser Strategie stark einschränkt.

Die *multi_maj* Strategie zeigte sehr variierende Ergebnisse mit einem F1-Score von 0.8446 für die Klasse 0 und 0 für die anderen Klassen, sowie einem sehr niedrigen Macro-F1-Wert von 0.1689. Die Precision und der Recall wiesen ähnliche Schwankungen auf, was auf eine extreme Inkonsistenz in der Modellleistung hinweist. Das Modell kann nur die Klasse 0 erkennen und versagt völlig bei der Erkennung aller anderen Klassen, was diese Strategie ebenfalls praktisch unbrauchbar macht.

Schließlich erreichte die Strategie *disagree_bin* einen F1-Score von 0.7737 für die Klasse 0 und 0.1946 für die Klasse 1 sowie einen Macro-F1 von 0.4842. Die Precision lag bei 0.6482 für die Klasse 0 und 0.6259 für die Klasse 1, während der Recall bei 0.9595 für die Klasse 0 und 0.1152 für die Klasse 1 lag. Dies zeigt, dass das Modell die Klasse 0 gut erkennt, aber auch Schwierigkeiten hat, die Klasse 1 zu identifizieren, obwohl es besser abschneidet als bei der *bin_maj* Strategie.

Insgesamt variieren die Ergebnisse stark. Die *bin_one* Strategie zeigte die ausgewogenste Leistung über alle Metriken hinweg. Im Gegensatz dazu wiesen *bin_all* und *multi_maj* erhebliche Probleme auf: *bin_all* konnte die Klasse 1 überhaupt nicht erkennen, und *multi_maj* versagte vollständig bei der Erkennung aller Klassen außer Klasse 0. Die [Tabelle 5.1](#) fasst die Ergebnisse zusammen:

Tabelle 5.1: Präsentiert werden die einzelnen Metriken zu den fünf Klassifikationsstrategien mit SVM ohne Modellanpassungen. Die erste Spalte der Metriken *F1-Score*, *Precision* und *Recall* zeigt das Ergebnis für Klasse 0, die rechte Spalte entsprechend die Ergebnisse für Klasse 1.

Strategie	F1 - Score		Macro - F1	Precision		Recall	
bin_maj	0.8105	0.0196	0.4150	0.6826	0.6333	0.9973	0.0099
bin_one	0.6812	0.5692	0.6252	0.5749	0.7586	0.8356	0.4555
bin_all	0.9124	0	0.4562	0.8389	0	1	0
multi_maj	0.8446 / 0	0 / 0 / 0	0.1689	0.7311 / 0	0 / 0 / 0	1 / 0	0 / 0 / 0
disagree_bin	0.7737	0.1946	0.4842	0.6482	0.6259	0.9595	0.1152

5.1.2 Ergebnisse mit Hyperparametertuning (SVM)

Nach dem Hyperparametertuning wurden die SVM-Modelle erneut trainiert und evaluiert:

Für die Strategie *bin_maj* zeigte das Modell nach dem Tuning einen F1-Score von 0.7887 und einen Macro-F1 von 0.6062. Die Precision lag bei 0.7376 für die Klasse 0 und bei 0.5222 für die Klasse 1. Der Recall war mit 0.8472 für die Klasse 0 hoch, jedoch für die Klasse 1 niedriger (0.3565). Im Vergleich zu den ursprünglichen Ergebnissen (F1-Score: 0.8105, Macro-F1: 0.4150) hat sich der Macro-F1-Wert verbessert, was auf eine ausgewogenere Leistung hinweist.

Die Strategie *bin_one* erreichte nach dem Tuning einen F1-Score von 0.6811 für die Klasse 0 und 0.5694 für die Klasse 1, sowie den höchsten Macro-F1-Wert von 0.6252. Die Precision und der Recall für diese Strategie waren 0.5750 und 0.7584 für die Klasse 0, bzw. 0.8352 und 0.4558 für die Klasse 1. Diese Werte sind nahezu identisch mit den ursprünglichen Ergebnissen (F1-Score: 0.6812, Macro-F1: 0.6252), was darauf hindeutet, dass das Hyperparametertuning hier keine signifikanten Verbesserungen gebracht hat.

Die *bin_all* Strategie erzielte nach dem Tuning einen F1-Score von 0.9124 für die Klasse 0 und 0 für die Klasse 1, was unverändert gegenüber den ursprünglichen Ergebnissen blieb. Der Macro-F1-Wert lag bei 0.4562, die Precision für die Klasse 0 bei 0.8390 und der Recall für die Klasse 0 bei 1, während die Klasse 1 überhaupt nicht erkannt wurde. Diese Strategie zeigt weiterhin erhebliche Probleme bei der Erkennung der Klasse 1.

Die *multi_maj* Strategie wurde nach dem Hyperparametertuning nicht bewertet. Dies ist mit den schlechten Ergebnissen der ursprünglichen Bewertung begründet.

Schließlich erreichte die Strategie *disagree_bin* nach dem Tuning einen F1-Score von 0.7755 für die Klasse 0 und 0.1988 für die Klasse 1, sowie einen Macro-F1 von 0.4871. Die Precision lag bei 0.6494 für die Klasse 0 und 0.6460 für die Klasse 1, während der Recall bei 0.9621 für die Klasse 0 und 0.1175 für die Klasse 1 lag. Diese Ergebnisse sind vergleichbar mit den ursprünglichen Ergebnissen (F1-Score: 0.7737, Macro-F1: 0.4842), wobei leichte Verbesserungen in der Balance zwischen Precision und Recall zu sehen sind.

Nach der Durchführung eines Grid-Search-Verfahrens wurde der Regularisierungsparameter C manuell auf 0,25 gesetzt, um ein Gleichgewicht zwischen einer breiten Marge und der Minimierung von Fehlklassifikationen zu erreichen. Zusätzlich wurde der Parameter *class_weight* auf 2 gesetzt, um die Gewichtung der Klassen anzupassen und dadurch die Auswirkungen von Klassenungleichgewichten auszugleichen.

Ungleichgewichtige Daten führen regelmäßig zu Ungenauigkeiten in der Leistungsmessung. Standardmetriken wie die Genauigkeit (*accuracy*) können irreführend sein. Ein Modell, das immer die

Mehrheitsklasse vorhersagt, kann eine hohe Genauigkeit aufweisen, aber schlecht darin sein, die Minderheitsklasse zu erkennen. Darüber hinaus tritt eine Verzerrung in der Modellleistung auf. Dies kann dazu führen, dass die häufigeren Klassen bevorzugt und die weniger häufigen Klassen ignoriert werden.

Insgesamt zeigt das Hyperparametertuning wie in [Tabelle 5.2](#) erkennbar, gemischte Ergebnisse. Während sich die Performance für *bin_maj* und *disagree_bin* leicht verbesserte, blieben die Ergebnisse für *bin_one* und *bin_all* weitgehend unverändert. Die *multi_maj* Strategie wurde nach dem Tuning nicht weiterverfolgt.

Tabelle 5.2: Präsentiert werden die einzelnen Metriken zu den fünf Klassifikationsstrategien mit SVM nach Hyperparametertuning. Die erste Spalte der Metriken *F1-Score*, *Precision* und *Recall* zeigt das Ergebnis für Klasse 0, die rechte Spalte entsprechend die Ergebnisse für Klasse 1.

Strategie	F1 - Score		Macro - F1	Precision		Recall	
bin_maj	0.7887	0.4237	0.6062	0.7376	0.5222	0.8472	0.3565
bin_one	0.6811	0.5694	0.6252	0.5750	0.7584	0.8352	0.4558
bin_all	0.9124	0	0.4562	0.8390	0	1	0
multi_maj	-	-	-	-	-	-	-
disagree_bin	0.7755	0.1988	0.4871	0.6494	0.6460	0.9621	0.1175

5.2 Ergebnisse der RF

In den folgenden Abschnitten werden die Ergebnisse des Trainings mit Random Forest vorgestellt. Der erste Abschnitt konzentriert sich auf das Training in der ersten Version. Der zweite Abschnitt präsentiert die Ergebnisse nach durchgeführten Optimierungen.

5.2.1 Ergebnisse ohne Hyperparametertuning (RF)

Für die Strategie *bin_maj* erzielte das Modell einen F1-Score von 0.8427 und einen Macro-F1 von 0.6638. Die Precision lag bei 0.7588 für die Klasse 0 und 0.7598 für die Klasse 1. Der Recall war mit 0.9474 für die Klasse 0 hoch, jedoch für die Klasse 1 niedriger (0.3560). Dies zeigt, dass das Modell die Klasse 0 gut erkennt, aber Schwierigkeiten hat, die Klasse 1 konsistent zu identifizieren.

Die Strategie *bin_one* erreichte einen F1-Score von 0.7335 für die Klasse 0 und 0.6753 für die Klasse 1 sowie den höchsten Macro-F1-Wert von 0.7044. Die Precision und der Recall für diese Strategie waren 0.6397 und 0.8221 für die Klasse 0, bzw. 0.8594 und 0.5730 für die Klasse 1. Diese Werte zeigen eine ausgewogenere Leistung im Vergleich zu *bin_maj*, mit besserer Erkennung der Klasse 1.

Die *bin_all* Strategie erzielte mit einem F1-Score von 0.9175 für die Klasse 0 und 0.1171 für die Klasse 1 die höchste Präzision von 0.8475 für die Klasse 0. Der Macro-F1-Wert lag bei 0.5173, was auf erhebliche Probleme bei der Erkennung der Klasse 1 hinweist. Das Modell erkennt die Klasse 1 fast gar nicht, was bedeutet, dass viele Instanzen dieser Klasse falsch klassifiziert werden.

Die *multi_maj* Strategie zeigte sehr variierende Ergebnisse, mit einem F1-Score von 0.8519 für die Klasse 0 und sehr niedrigen Werten für die anderen Klassen. Der Macro-F1-Wert lag bei 0.2308. Die Precision und der Recall wiesen extreme Schwankungen auf, was auf eine inkonsistente Modellleistung hinweist. Das Modell kann nur die Klasse 0 einigermaßen gut erkennen und versagt bei der

Erkennung der anderen Klassen. Die Situation entspricht der SVM-Evaluation.

Schließlich erreichte die Strategie *disagree_bin* einen F1-Score von 0.8317 für die Klasse 0 und 0.5426 für die Klasse 1 sowie einen Macro-F1 von 0.6872. Die Precision lag bei 0.7305 für die Klasse 0 und 0.8706 für die Klasse 1, während der Recall bei 0.9656 für die Klasse 0 und 0.3941 für die Klasse 1 lag. Dies zeigt, dass das Modell die Klasse 0 gut erkennt, aber auch hier Schwierigkeiten hat, die Klasse 1 zuverlässig zu identifizieren.

Insgesamt variieren die Ergebnisse ebenfalls stark je nach gewählter Strategie. Die *bin_one* Strategie zeigte die ausgewogenste Leistung über alle Metriken hinweg. Im Gegensatz dazu wiesen *bin_all* und *multi_maj* erhebliche Probleme auf: *bin_all* konnte die Klasse 1 fast gar nicht erkennen, und *multi_maj* versagte bei der Erkennung aller Klassen außer Klasse 0. [Tabelle 5.3](#) fasst die Evaluation zusammen:

Tabelle 5.3: Präsentiert werden die einzelnen Metriken zu den fünf Klassifikationsstrategien mit RF ohne Modellanpassungen. Die erste Spalte der Metriken *F1-Score*, *Precision* und *Recall* zeigt das Ergebnis für Klasse 0, die rechte Spalte entsprechend die Ergebnisse für Klasse 1.

Strategie	F1 - Score		Macro - F1	Precision		Recall	
bin_maj	0.8427	0.4848	0.6638	0.7588	0.7598	0.9474	0.3560
bin_one	0.7335	0.6753	0.7044	0.6397	0.8221	0.8594	0.5730
bin_all	0.9175	0.1171	0.5173	0.8475	1	1	0.0622
multi_maj	0.8519 /	0.0930 /	0.2308	0.7420 /	1 / 1 / 0	1	/ 0.0488 /
	0.1091	0.1 / 0		1		0.0577	0.0526 /
							0
disagree_bin	0.8317	0.5426	0.6872	0.7305	0.8706	0.9656	0.3941

5.2.2 Ergebnisse mit Hyperparameter tuning (RF)

Für die Strategie *bin_maj* zeigte das Modell nach dem Tuning einen F1-Score von 0.8679 und einen Macro-F1 von 0.7441. Die Precision lag bei 0.8025 für die Klasse 0 und 0.8101 für die Klasse 1. Der Recall war mit 0.9449 für die Klasse 0 hoch und für die Klasse 1 bei 0.5026. Im Vergleich zu den ursprünglichen Ergebnissen (F1-Score: 0.8427, Macro-F1: 0.6638) zeigt sich eine deutliche Verbesserung des Macro-F1-Werts.

Die *bin_one* Strategie erzielte nach dem Tuning einen F1-Score von 0.7450 für die Klasse 0 und 0.6930 für die Klasse 1 sowie einen Macro-F1-Wert von 0.7190. Die Precision und der Recall für diese Strategie lagen bei 0.6524 und 0.8359 für die Klasse 0 sowie 0.8683 und 0.8359 für die Klasse 1. Diese Werte zeigen eine leichte Verbesserung im Vergleich zu den ursprünglichen Ergebnissen (F1-Score: 0.7335, Macro-F1: 0.7044), insbesondere im Recall für die Klasse 1.

Die *bin_all* Strategie erzielte nach dem Tuning einen F1-Score von 0.9125 für die Klasse 0 und 0 für die Klasse 1, was keine Veränderung zu den ursprünglichen Ergebnissen darstellt. Der Macro-F1-Wert blieb bei 0.4562, die Precision für die Klasse 0 bei 0.8390 und der Recall für die Klasse 0 bei 1, während die Klasse 1 überhaupt nicht erkannt wurde. Diese Strategie bleibt problematisch in Bezug auf die Erkennung der Klasse 1.

Die *multi_maj* Strategie zeigte nach dem Hyperparameter tuning ebenfalls keine signifikanten Verbesserungen und blieb bei einem F1-Score von 0.8453 für die Klasse 0 und 0 für die anderen Klassen. Der Macro-F1-Wert lag bei 0.1691. Die Precision und der Recall wiesen erhebliche Schwankungen

auf, was auf eine unzuverlässige Modellleistung hinweist. Das Modell kann nur die Klasse 0 einigermaßen gut erkennen und versagt bei der Erkennung der anderen Klassen, was diese Strategie unbrauchbar macht.

Schließlich erreichte die Strategie *disagree_bin* nach dem Tuning einen F1-Score von 0.8341 für die Klasse 0 und 0.5538 für die Klasse 1 sowie einen Macro-F1 von 0.6940. Die Precision lag bei 0.7341 für die Klasse 0 und 0.8738 für die Klasse 1, während der Recall bei 0.9656 für die Klasse 0 und 0.4054 für die Klasse 1 lag. Diese Ergebnisse zeigen leichte Verbesserungen gegenüber den ursprünglichen Ergebnissen (F1-Score: 0.8317, Macro-F1: 0.6872), insbesondere in der Precision für die Klasse 1.

Insgesamt zeigt das Hyperparametertuning gemischte Ergebnisse. Während die Performance für *bin_maj*, *bin_one*, und *disagree_bin* leicht verbessert wurde, blieben die Ergebnisse für *bin_all* und *multi_maj* weitgehend unverändert. Die *bin_maj* Strategie zeigte nach dem Tuning die ausgewogenste Leistung. Im Gegensatz dazu wiesen *bin_all* und *multi_maj* weiterhin erhebliche Schwierigkeiten auf: *bin_all* konnte die Klasse 1 fast gar nicht erkennen, und *multi_maj* versagte bei der Erkennung aller Klassen außer der Klasse 0. [Tabelle 5.4](#) zeigt die zusammengefassten Ergebnisse:

Tabelle 5.4: Präsentiert werden die einzelnen Metriken zu den fünf Klassifikationsstrategien mit RF nach Hyperparametertuning. Die erste Spalte der Metriken *F1-Score*, *Precision* und *Recall* zeigt das Ergebnis für Klasse 0, die rechte Spalte entsprechend die Ergebnisse für Klasse 1.

Strategie	F1 - Score		Macro - F1	Precision		Recall	
bin_maj	0.8679	0.6204	0.7441	0.8025	0.8101	0.9449	0.5026
bin_one	0.7450	0.6930	0.7190	0.6524	0.8359	0.8683	0.8359
bin_all	0.9125	0	0.4562	0.8390	0	1	0
multi_maj	0.8453 / 0	0 / 0 / 0	0.1691	0.7321 / 0	0 / 0 / 0	1 / 0	0 / 0 / 0
disagree_bin	0.8341	0.5538	0.6940	0.7341	0.8738	0.9656	0.4054

5.3 Vergleich der Modelle

Das Training der SVM- und RF-Modelle ergab unterschiedliche Ergebnisse. Die SVM-Modelle erzielten unterdurchschnittliche Leistungen, und selbst nach Optimierung wurden Verbesserungen nur für die *bin_maj*-Strategie beobachtet. Im Gegensatz dazu schnitten die RF-Modelle allgemein besser ab. Da die Parameterabstimmung für beide Modelle entweder nicht erfolgreich oder nur teilweise erfolgreich war, sollten die folgenden Maßnahmen zur weiteren Optimierung in Betracht gezogen werden:

Weitere Optimierung der Hyperparameter: Um die Klassifikationsleistung, insbesondere für die negative Klasse, weiter zu verbessern, sollten zusätzliche Hyperparameter-Tuning-Schritte in Betracht gezogen werden.

Datenbalance: Der Einsatz von Techniken wie SMOTE (Synthetic Minority Over-sampling Technique) könnte dazu beitragen, die Klassenbalance im Datensatz zu verbessern und somit die Modellleistung zu erhöhen (Chawla et al., 2002).

Feature Engineering: Weitere Untersuchungen zur Verbesserung der Merkmale könnten helfen, die Klassifikationsleistung zu optimieren.

Das Experiment zeigte, dass durch gezieltes Hyperparameter-Tuning Verbesserungen in der Klassifi-

kationsleistung erzielt werden können. Obwohl die abgestimmten Ergebnisse der SVM-Modelle eine etwas ausgewogenere Leistung zwischen den Klassen zeigen (zumindest für die *bin_maj*-Strategie), bleibt der Random Forest (RF) das robustere Modell mit der besseren Gesamtleistung.

5.4 Herausforderungen und Limitationen

Während bzw. nach Fertigstellung dieser Arbeit konnten mehrere Herausforderungen und Limitationen festgestellt werden, die Einfluss auf die Modellresultate hatten:

1. Datenqualität und -umfang:

Eine zentrale Herausforderung war der Umfang der bereitgestellten Daten. Der Trainingsdatensatz in der Entwicklungsphase umfasste 4486 Kommentare. In der Wettbewerbsphase erhöhte sich die Menge an gelabelten Sätzen zwar auf 5998 Kommentare aber es bleibt festzustellen, dass eine sehr große Datenmenge signifikant für das Training eines effizienten Machine-Learning-Modells ist (Goodfellow et al., 2016). So bestand die Gefahr, dass die begrenzte Datenmenge und mögliche Verzerrungen in den Daten die Generalisierbarkeit und Genauigkeit der Modelle beeinträchtigt haben könnten.

2. Ungleichgewicht der Klassen:

Ebenfalls direkt aus den bereitgestellten Daten ergab sich die Herausforderung bzgl. des Umgangs mit unausgewogenen Klassenverteilungen (z.B. deutlich mehr nicht-sexistische als sexistische Texte). Durch dieses starke Klassenungleichgewicht bestand die Gefahr, dass die Modelle weniger empfindlich gegenüber der Minderheitsklasse (sexistische Texte) sind und deren Erkennung dadurch beeinträchtigt wird. Diese Aussage bestätigte auch die Evaluation der Modelle in [Kapitel 5](#). Insbesondere die Strategien „bin_all“ und „multi_maj“ versagten völlig bei der Sexismus-Detektion.

3. Feature-Selektion und Modellkomplexität:

Die Auswahl der relevanten Features für das Training der Modelle und deren Anzahl stellte ebenfalls eine Herausforderung dar. Insbesondere die Entscheidung, welche Wörter und Emotionen in die TF-IDF- und Sentimentanalyse einfließen sollten und wie deren Einfluss zu bewerten sei, war nicht trivial. Dabei ist anzumerken, dass eine unzureichende oder falsche Feature-Selektion zu suboptimalen Modellergebnissen führen kann.

4. Sentimentanalyse und emotionale Nuancen:

Die korrekte Erkennung und Gewichtung emotionaler Nuancen in Texten war nicht eindeutig differenzierbar. Beispielsweise wurden die Wörter „Frau“ bzw. „Mann“ nach Sentimentanalyse jeweils positiv als auch negativ bewertet. Das wirft die Frage auf, ob eine N-Gramm - Analyse als eine alternative oder ergänzende Textklassifikationsmethode sinnvoll gewesen wäre (Manning et al., 2008). Wie bereits erläutert, sind emotionale Kontexte oft subtil und schwer zu quantifizieren. Das erschwert das Modelltraining insbesondere in den Fällen, in denen sexistische Inhalte in subtilen oder ironischen Kommentaren versteckt sind.

Diese Herausforderungen und Limitationen beeinflussten die Arbeit und mussten bei der Interpretation der Ergebnisse berücksichtigt werden. Sie zeigen die Komplexität und die technischen Schwierigkeiten bei der Entwicklung eines effizienten Systems zur automatischen Sexismusdetektion in deutschsprachigen Texten.

Andere, häufig auftretende Schwierigkeiten beim Training von Modellen wie eine sehr zeitaufwändige oder ressourcenintensive Berechnung waren in diesem Fall aufgrund des kleinen Datensatzes kein Thema.

5.5 Potentielle Verbesserungen und zukünftige Arbeiten

Um die Genauigkeit und Generalisierbarkeit der Modelle zur automatischen Sexismusdetektion in deutschsprachigen Texten zu verbessern, sind folgende Maßnahmen zu prüfen:

Eine wesentliche Verbesserung besteht in der Erweiterung und Diversifizierung der Datensätze. Durch die Sammlung größerer und repräsentativerer Datenmengen, die verschiedene Kontexte und Variationen sexistischer Sprache abdecken, kann die Robustheit und Genauigkeit der Modelle gesteigert werden. Ein weiterer Ansatzpunkt für zukünftige Arbeiten ist die Verfeinerung der Feature-Selektion. Der Einsatz fortschrittlicherer Techniken zur automatischen Merkmalerkennung, wie etwa neuronale Netzwerke oder transformerbasierte Modelle könnte helfen, relevantere und aussagekräftigere Features zu identifizieren. Diese Techniken könnten auch dabei unterstützen, subtile emotionale Nuancen und ironische Kommentare besser zu erkennen und zu gewichten. Ebenso könnte eine verbesserte Sentimentanalyse, die speziell auf die Erkennung von für Sexismus relevanten Emotionen trainiert ist, die Modellergebnisse weiter optimieren.

Um die Herausforderungen bei der Erkennung von Sexismus zu bewältigen, werden fortgeschrittene NLP-Techniken und tiefere Modelle des maschinellen Lernens benötigt, die besser in der Lage sind, den Kontext und die Nuancen der Sprache zu verstehen. Die Entwicklung von Fairness- und Ethikrichtlinien, die Einbeziehung von Experten aus den Geistes- und Sozialwissenschaften und die Schaffung diverser und umfassender Datensätze sind ebenfalls entscheidend. Darüber hinaus wird an der Schaffung von Richtlinien und Rahmenbedingungen gearbeitet, die den verantwortungsvollen Einsatz von Sexismus-Detektionssystemen fördern (Ehsan et al., 2021).

Zudem könnten ensemblerbasierte Methoden, die verschiedene Modelle kombinieren, genutzt werden, um die Vorhersagegenauigkeit zu erhöhen und die Gefahr der Überanpassung zu verringern. Ein weiterer wichtiger Aspekt ist die Erhöhung der Transparenz und Interpretierbarkeit der Modelle, um besser zu verstehen, wie und warum bestimmte Entscheidungen getroffen werden. Schließlich könnte die Integration von domänenspezifischem Wissen und die Zusammenarbeit mit Experten auf dem Gebiet der Genderforschung und Linguistik dazu beitragen, die Modelle weiter zu verbessern. Durch die Einbindung dieses Fachwissens könnten Modelle entwickelt werden, die nicht nur technische Genauigkeit bieten, sondern auch eine tiefere kulturelle und soziale Sensibilität aufweisen.

6 Fazit und Ausblick

In dieser Arbeit wurde die automatische Erkennung von Sexismus in deutschsprachigen Texten untersucht. Zwei Machine-Learning-Modelle wurden mit verschiedenen Klassifikationsstrategien trainiert und evaluiert. Dabei sollte untersucht werden, inwieweit abweichende Annotatorenmeinungen beim Training berücksichtigt werden können und Meinungen von Annotatoren bei Anwendung auf einen neuen Text divergieren.

Wie die Datenexploration zeigte, bestand neben einer großen Ungleichverteilung der Label eine Herausforderung in den hohen Varianzen in der Klassifikation der Annotatoren sowie im Umfang der Anzahl an Annotationen pro Text. Daher wurden in der Vorverarbeitung potentielle Ausreißer mittels Z-Score identifiziert. Der Ansatz wurde aufgrund der geringen Anzahl an Ausreißern nicht weiter verfolgt. Es wurden dann die vorhandenen Varianzen im Zuge einer NA-Wert - Handhabung durch eine k-Nearest-Neighbor (k-NN) Imputation geglättet. Im Ergebnis lag ein vollständiger, annotierter und geglätteter Datensatz zum Modelltraining vor. Nach dieser Vorverarbeitung erfolgte das Feature-Engineering durch TF-IDF und Sentimentanalyse. Als Klassifikationsalgorithmen wurden RF und SVM verwendet, deren Hyperparameter mittels Grid Search optimiert wurden.

Anschließend wurden die Modelle evaluiert. Sowohl vor als auch nach Hyperparametertuning wurden für SVM und RF Metriken erhoben. Insbesondere die einfache Mehrheitsvotierung (bin_maj), nach der ein Text das Label „sexistisch“ bekommt wenn die Mehrheit der Annotatoren der Meinung ist das es sexistisch ist und entsprechend als nicht sexistisch eingestuft wird wenn die Mehrheit der Annotatoren das bewertet führte zu akzeptablen bis guten Ergebnissen.

Ähnliche Ergebnisse erzielte die Klassifikationsentscheidung, das wenn mindestens ein Annotator den Text als sexistisch eingestuft hat der Satz insgesamt als ebenfalls als sexistisch bewertet wurde (bin_one). Die Resultate waren bei beiden Modellen vergleichbar.

Gegenteilig verhielt sich die Modellperformance bei den Strategien bin_all und multi_maj. Ausschlaggebend waren die nicht vorhandene Erkennungsleistung von sexistischen Texten. Zu den ursächlichen Problemen zählten mehrere Faktoren, insbesondere der geringe Umfang der gelabelten Trainingsdaten, die Unausgeglichenheit der Klassen, die Feature-Selection und Modellkomplexität sowie die Sentimentanalyse und die emotionalen Nuancen. Abschließend sollen die in [Abschnitt 1.2](#) aufgestellten Fragestellungen bewertet werden:

Lassen sich durch die verwendeten Machine-Learning-Modelle und Mehrheitsstrategien Rückschlüsse darauf ziehen inwieweit die Meinungen von Annotatoren bei Anwendung auf einen neuen Text divergieren?

Es wurde festgestellt, dass die verwendeten Modelle und Mehrheitsstrategien Hinweise auf die Divergenz der Meinungen von Annotatoren geben können. Durch Analyse der Modellvorhersagen bzw. durch die Auswertung der Vorhersagen auf neue Texte können wir erkennen, wie oft das Modell unsicher ist oder widersprüchliche Klassifikationen liefert, was auf divergierende Meinungen der Annotatoren hinweist. Alternativ können Modelle wie Random Forests die Unsicherheit ihrer Vorhersagen quantifizieren, was genutzt werden kann, um Bereiche mit hoher Meinungsdivergenz zu identifizieren. Zuletzt besteht die Möglichkeit einer Validierung mit neuen Annotationen. Die Anwendung der Modelle auf neue Texte und die anschließende Validierung durch zusätzliche Annotatoren könnte dann Aufschluss darüber geben, inwieweit die ursprünglichen Meinungen divergieren.

Welche der beiden traditionellen Algorithmen - SVM oder Random-Forest - liefert bessere Ergebnisse bei der Klassifikation unter Verwendung verschiedener Strategien und inwiefern führt das Fine-Tuning von Hyperparametern zu Performance-Verbesserungen?

Die vorliegenden Ergebnisse zeigen, dass Random-Forest-Algorithmen tendenziell bessere Leistungen bei der Klassifikation erbringen als SVMs, insbesondere wenn verschiedene Strategien verwendet werden. Random Forests bieten eine höhere Vorhersagegenauigkeit und eine bessere Balance zwischen den Klassen. Das Hyperparametertuning führt bei beiden Algorithmen zu Leistungsverbesserungen, wobei bei Random Forests signifikante Verbesserungen in der Genauigkeit beobachtet wurden. Bei SVMs waren die Verbesserungen durch das Feintuning der Hyperparameter weniger konsistent und zeigten nur in bestimmten Strategien nennenswerte Fortschritte. Insgesamt bieten Random Forests durch ihre Flexibilität und Robustheit einen Vorteil gegenüber SVMs in der Klassifikation.

Literaturverzeichnis

- Arif, A. (2023). How Cross-Validation works in Machine Learning [Online; last checked: 28.07.2024]. <https://dataaspirant.com/cross-validation/>
- Băroiu, A.-C., & Trăușan-Matu, Ș. (2022). Automatic Sarcasm Detection: Systematic Literature Review. *Information*, 13(8). <https://doi.org/10.3390/info13080399>
- Bassignana, E., Basile, V., & Patti, V. (2018, Januar). Hurtlex: A Multilingual Lexicon of Words to Hurt. <https://doi.org/10.4000/books.aaccademia.3085>
- Baumgarten, N. (2017). Othering Practice in a Right-Wing Extremist Online Forum. *Language@Internet*, 14.
- Beck, J. (2023). Quality aspects of annotated data: A research synthesis. *AStA Wirtschafts- und Sozialstatistisches Archiv*, 17. <https://doi.org/10.1007/s11943-023-00332-y>
- Bland, J. M., & Altman, D. G. (1995). Calculating correlation coefficients with repeated observations: Part 1—Correlation within subjects. *BMJ (Clinical research ed.)*, 310(6977), 446. <http://www.pubmedcentral.nih.gov/articlerender.fcgi?artid=2548822&tool=pmcentrez&rendertype=abstract>
- Boser, B. E., Guyon, I. M., & Vapnik, V. N. (1992). A training algorithm for optimal margin classifiers. *Proceedings of the Fifth Annual Workshop on Computational Learning Theory*, 144–152. <https://doi.org/10.1145/130385.130401>
- Bou-Franch, P., & Blitvich, P. G.-C. (2016). Gender ideology and social identity processes in online language aggression against women. *Exploring language aggression against women*, 59–81.
- Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). Classification and Regression Trees.
- Breiman, L. (1996). Bagging predictors. *Mach. Learn.*, 24(2), 123–140. <https://doi.org/10.1023/A:1018054314350>
- Breiman, L. (2001). Random Forests. *Mach. Learn.*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Brital, A. (2021). Random Forest Algorithm Explained. [Online; last checked: 16.07.2024]. <https://anasbrital98.github.io/blog/2021/Random-Forest/>
- Brownlee, J. (2017). Difference Between Classification and Regression in Machine Learning [Accessed: 2024-08-07].
- Butt, S., Ashraf, N., Sidorov, G., & Gelbukh, A. F. (2021). Sexism Identification using BERT and Data Augmentation - EXIST2021. *IberLEF@SEPLN*. <https://api.semanticscholar.org/CorpusID:238207384>
- Cabello-Solorzano, K., Araujo, I., Cubillos, M. P., Correia, L., & Tallón-Ballesteros, A. J. (2023, August). The Impact of Data Normalization on the Accuracy of Machine Learning Algorithms: A Comparative Analysis. https://doi.org/10.1007/978-3-031-42536-3_33
- Cañete, J., Donoso, S., Bravo-Marquez, F., Carvallo, A., & Araujo, V. (2023). ALBETO and DistilBETO: Lightweight Spanish Language Models. <https://arxiv.org/abs/2204.09145>
- Caselli, T., Basile, V., Mitrović, J., & Granitzer, M. (2021, August). HateBERT: Retraining BERT for Abusive Language Detection in English. In A. M. Davani, D. Kiela, M. Lambert, B. Vidgen, V. Prabhakaran & Z. Waseem (Hrsg.), *Proceedings of the 5th Workshop on Online Abuse and Harms (WOAH 2021)* (S. 17–25). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.woah-1.3>

- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Chowdhery, A., Narang, S., Devlin, J., Bosma, M., Mishra, G., Roberts, A., Barham, P., Chung, H. W., Sutton, C., Gehrmann, S., Schuh, P., Shi, K., Tsvyashchenko, S., Maynez, J., Rao, A., Barnes, P., Tay, Y., Shazeer, N., Prabhakaran, V., . . . Fiedel, N. (2022). PaLM: Scaling Language Modeling with Pathways. <https://arxiv.org/abs/2204.02311>
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates.
- Coll, J. (2020). Advantages And Pitfalls Of Using The Z Score [Online; last checked: 28.07.2024]. <https://statcalculators.com/advantages-and-pitfalls-of-using-the-z-score/>
- Commission, E. (2016). Code of conduct on countering illegal hate speech online [Online; last checked: 02.07.2024]. https://commission.europa.eu/strategy-and-policy/policies/justice-and-fundamental-rights/combating-discrimination/racism-and-xenophobia/eu-code-conduct-countering-illegal-hate-speech-online%5C_en
- Cortes, C., & Vapnik, V. (1995). Support Vector Networks. *Machine Learning*, 20, 273–297.
- Cristianini, N., & Shawe-Taylor, J. (2000). *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge University Press. http://www.amazon.com/Introduction-Support-Machines-Kernel-based-Learning/dp/0521780195/ref=sr_1_1?ie=UTF8&s=books&qid=1280243230&sr=8-1
- de Paula, A. F. M., da Silva, R. F., & Schlicht, I. B. (2021). Sexism Prediction in Spanish and English Tweets Using Monolingual and Multilingual BERT and Ensemble Models. <https://arxiv.org/abs/2111.04551>
- Devlin, J., Chang, M., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *CoRR*, abs/1810.04805. <http://arxiv.org/abs/1810.04805>
- Diaz, G., Suriyawongkul, A., Pukhalskyi, M., & Solomon, B. (2020). stopwords-iso [Online; last checked: 28.07.2024]. <https://github.com/stopwords-iso/stopwords-iso>
- Dictionary, O. E. (2024, März). misogyny, n. [Online; last checked: 27.07.2024]. https://www.oed.com/dictionary/misogyny%5C_n?tab=factsheet%5C#36725941
- Dolezalek, C., Fielitz, M., Heindl, C., Jaki, D. S., & Schwarz, K. (2024). Bundesarbeitsgemeinschaft »Gegen Hass im Netz«, Textgain (2024): Tracing Online Misogyny. Eine quantitative und qualitative Analyse verschiedener Facetten der Manosphere und misogynen Praxis im deutsch-internationalen Vergleich. [Online; last checked: 27.07.2024]. https://bag-gegen-hass.net/wp-content/uploads/2024/03/NETTZ%5C_studie%5C_50%5C_doppelseitig-1.pdf
- Duggan, M. (2014, Oktober). Online Harassment [Online; last checked: 16.07.2024]. <https://www.pewresearch.org/internet/2014/10/22/online-harassment/>
- Ehsan, U., Liao, Q. V., Muller, M., Riedl, M. O., & Weisz, J. D. (2021). Expanding Explainability: Towards Social Transparency in AI systems. *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. <https://doi.org/10.1145/3411764.3445188>
- Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. *Proc. of 2nd International Conference on Knowledge Discovery and*, 226–231.
- Feldman, K. (2023). Z-Score: A Handy Tool for Detecting Outliers in Data [Online; last checked: 28.07.2024]. <https://www.isixsigma.com/dictionary/z-score/>
- Fortuna, P., & Nunes, S. (2018). A Survey on Automatic Detection of Hate Speech in Text. *ACM Computing Surveys*, 51, 1–30. <https://doi.org/10.1145/3232676>

- Fox, J., Cruz, C., & Lee, J. Y. (2015). Perpetuating online sexism offline: Anonymity, interactivity, and the effects of sexist hashtags on social media. *Computers in Human Behavior*, 52, 436–442. <https://doi.org/https://doi.org/10.1016/j.chb.2015.06.024>
- G, M., & Oppenlaender, J. (2016). german_stopwords [Online; last checked: 28.07.2024]. https://github.com/solariz/german%5C_stopwords
- Gandhi, R. (2018). Introduction to Machine Learning Algorithms, SVM model from scratch [Online; last checked: 16.07.2024]. <https://towardsdatascience.com/support-vector-machine-introduction-to-machine-learning-algorithms-934a444fca47>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. <http://www.deeplearningbook.org>
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining concepts and techniques, third edition*. http://www.amazon.de/Data-Mining-Concepts-Techniques-Management/dp/0123814790/ref=tmm_hrd_title_0?ie=UTF8&qid=1366039033&sr=1-1
- Hassija, V., Chamola, V., Mahapatra, A., Singal, A., Goel, D., Huang, K., Scardapane, S., Spinelli, I., Mahmud, M., & Hussain, A. (2023). Interpreting Black-Box Models: A Review on Explainable Artificial Intelligence. *Cognitive Computation*, 16. <https://doi.org/10.1007/s12559-023-10179-8>
- Hastie, T., Tibshirani, R., & Friedman, J. (2001). *The Elements of Statistical Learning*. Springer New York Inc.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd). *Springer Series in Statistics*.
- Hoffmann, L. (2020). Zur Sprache des Rassismus. *Sprachreport*, 36(1), 40–47.
- Howard, J., & Ruder, S. (2018). Universal Language Model Fine-tuning for Text Classification. <https://arxiv.org/abs/1801.06146>
- Jaki, S., Smedt, T. D., Gwozdz, M., Panchal, R., Rossa, A., & Pauw, G. (2019). Online hatred of women in the Incels.me Forum: Linguistic analysis and automatic detection. *Journal of Language Aggression and Conflict*, 7. <https://doi.org/10.1075/jlac.00026.jak>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: with Applications in R*. Springer New York. https://books.google.de/books?id=qcl%5C_AAAAQBAJ
- Jiang, A., & Zubiaga, A. (2021). QMUL-SDS at EXIST: Leveraging Pre-trained Semantics and Lexical Features for Multilingual Sexism Detection in Social Networks. *IberLEF@SEPLN*. <https://api.semanticscholar.org/CorpusID:237361709>
- Joshi, A., Dabre, R., Kanojia, D., Li, Z., Zhan, H., Haffari, G., & Dippold, D. (2024). Natural Language Processing for Dialects of a Language: A Survey. <https://arxiv.org/abs/2401.05632>
- Karthikeyan, B., Sundarraj, S., Sampathkumar, C., Mouthami, K., & Yuvaraj, N. (2023). Sexism Classification in Social Media Using Machine Learning Algorithms. In A. Abraham, T. Hanne, N. Gandhi, P. M. Mishra, A. Bajaj & P. Siarry (Hrsg.), *Proceedings of the 14th International Conference on Soft Computing and Pattern Recognition (SoCPaR 2022)* (S. 14–23). Springer Nature Switzerland.
- Kirk, H., Yin, W., Vidgen, B., & Röttger, P. (2023, Juli). SemEval-2023 Task 10: Explainable Detection of Online Sexism. In A. K. Ojha, A. S. Doğruöz, G. D. S. Martino, H. T. Madabushi, R. Kumar & E. Sartori (Hrsg.), *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)* (S. 2193–2210). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2023.semeval-1.305>
- Kiss, E. M. (2020). *Maschnielles Lernen: Konzepte, Methoden, Tools* (Techn. Ber.) (Online; last checked: 16.07.2024). elab2go - Mobile Engineering Lab. <https://www.elab2go.de/ml/>

- Kohonen, T. (1988). An introduction to neural computing. *Neural Networks*, 1(1), 3–16. [https://doi.org/10.1016/0893-6080\(88\)90020-2](https://doi.org/10.1016/0893-6080(88)90020-2)
- Kreis, R. (2017). #refugeesnotwelcome: Anti-refugee discourse on Twitter. *Discourse & Communication*, 11(5), 498–514. <https://doi.org/10.1177/1750481317714121>
- Krenn, B., Petrak, J., & Gross, S. (2024). GermEval2024 GerMS-Detect [Online; last checked: 27.07.2024]. <https://ofai.github.io/GermEval2024-GerMS/subtask1.html>
- Krutzfeldt, L. (2023). Wie funktioniert Machine Learning 2023? Inkl. Beispielen [Online; last checked: 17.07.2024]. <https://stackfuel.com/de/blog/machine-learning-algorithmen-data-analytics/>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *nature*, 521(7553), 436.
- Liu, Q., & Wu, Y. (2012). Supervised Learning. In N. M. Seel (Hrsg.), *Encyclopedia of the Sciences of Learning* (S. 3243–3245). Springer US. https://doi.org/10.1007/978-1-4419-1428-6_451
- Liu, X., Wang, Y., Ji, J., Cheng, H., Zhu, X., Awa, E., He, P., Chen, W., Poon, H., Cao, G., & Gao, J. (2020). The Microsoft Toolkit of Multi-Task Deep Neural Networks for Natural Language Understanding. *CoRR*, abs/2002.07972. <https://arxiv.org/abs/2002.07972>
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A Robustly Optimized BERT Pretraining Approach. <https://arxiv.org/abs/1907.11692>
- Makowski, J. (2020). *Hassrede: ein multidimensionales Phänomen im interdisziplinären Vergleich*. Wydawnictwo Uniwersytetu Łódzkiego. <https://books.google.de/books?id=-ajGzQEACAAJ>
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. <http://nlp.stanford.edu/IR-book/information-retrieval-book.html>
- Marwick, A. E., & Miller, R. W. (2014). Online Harassment, Defamation, and Hateful Speech: A Primer of the Legal Landscape. <https://api.semanticscholar.org/CorpusID:140290490>
- Mironczuk, M., & Protasiewicz, J. (2018). A Recent Overview of the State-of-the-Art Elements of Text Classification. *Expert Systems with Applications*, 106. <https://doi.org/10.1016/j.eswa.2018.03.058>
- Mittal, A. (2017). Machine Learning Process And Scenarios [Online; last checked: 17.07.2024]. <https://elearningindustry.com/machine-learning-process-and-scenarios>
- Mohammad, S. M., & Turney, P. D. (2013). CROWDSOURCING A WORD-EMOTION ASSOCIATION LEXICON. *Computational Intelligence*, 29(3), 436–465. <https://doi.org/10.1111/j.1467-8640.2012.00460.x>
- Mohseni, M. R. (2021). Sexistische Online-Hassrede auf Videoplattformen. In S. Wachs, B. Koch-Priewe & A. Zick (Hrsg.), *Hate Speech - Multidisziplinäre Analysen und Handlungsoptionen: Theoretische und empirische Annäherungen an ein interdisziplinäres Phänomen* (S. 39–51). Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-31793-5_3
- Murti, D. M. P., Pujiato, U., Wibawa, A. P., & Akbar, M. I. (2019). K-Nearest Neighbor (K-NN) based Missing Data Imputation. *2019 5th International Conference on Science in Information Technology (ICSITech)*, 83–88. <https://doi.org/10.1109/ICSITech46713.2019.8987530>
- Murty, M., & Raghava, R. (2016). *Support Vector Machines and Perceptrons: Learning, Optimization, Classification, and Application to Social Networks* (1st). Springer Publishing Company, Incorporated.
- Park, K., Ging, D., Murphy, S., & McGrath, C. (2023). The impact of the use of social media on women and girls [Online; last checked: 02.07.2024]. [https://www.europarl.europa.eu/RegData/etudes/STUD/2023/743341/IPOL%5C_STU\(2023\)743341%5C_EN.pdf](https://www.europarl.europa.eu/RegData/etudes/STUD/2023/743341/IPOL%5C_STU(2023)743341%5C_EN.pdf)
- Pelzer, B., Kaati, L., Cohen, K., & Fernquist, J. (2021). Toxic language in online incel communities. *SN Social Sciences*, 1. <https://doi.org/10.1007/s43545-021-00220-8>

- Plaza, L., Carrillo-de-Albornoz, J., Amigó, E., Gonzalo, J., Morante, R., Rosso, P., Spina, D., Chulvi, B., Maeso, A., & Garcia, V. R. (2024, März). EXIST 2024: sEXism Identification in Social neTworks and Memes. https://doi.org/10.1007/978-3-031-56069-9_68
- Plutchik, R. (1980). Plutchik's Wheel of Emotions: Exploring the Emotion Wheel [Online; last checked: 17.07.2024]. <https://www.6seconds.org/2022/03/13/plutchik-wheel-emotions/>
- Prabhakaran, S. (2023). How to detect outliers with z-score [Online; last checked: 28.07.2024]. <https://www.machinelearningplus.com/machine-learning/how-to-detect-outliers-with-z-score/>
- Ramos, J. (1999). Using TF-IDF to Determine Word Relevance in Document Queries.
- Rodrigo-Ginés, F.-J., Carrillo-de-Albornoz, J., & Plaza, L. (2021). UNEDBiasTeam at IberLEF 2021's EXIST Task: Detecting Sexism Using Bias Techniques.
- Rodríguez-Sánchez, F. J., Carrillo-de-Albornoz, J., Plaza, L., Gonzalo, J., Rosso, P., Comet, M., & Donoso, T. (2021). Overview of EXIST 2021: sEXism Identification in Social neTworks. *Proces. del Leng. Natural*, 67, 195–207. <https://api.semanticscholar.org/CorpusID:250527210>
- Rodríguez-Sánchez, F., Carrillo-de-Albornoz, J., Gonzalo, J., Plaza, L., Comet, M., Rosso, P., & Donoso, T. (2021). EXIST: sEXism Identification in Social neTworks, First Shared Task at IberLEF 2021 [Online; last checked: 28.07.2024]. <http://nlp.uned.es/exist2021/>
- Rother, K., & Rettberg, A. (2018). ULMFiT at GermEval-2018: A Deep Neural Language Model for the Classification of Hate Speech in German Tweets.
- Ruppenhofer, J., Siegel, M., & Wiegand, M. (Hrsg.). (2019). *Proceedings of GermEval 2018, 14th Conference on Natural Language Processing (KONVENS 2018), Vienna, Austria – September 21, 2018*. Austrian Academy of Sciences. <https://nbn-resolving.org/urn:nbn:de:bsz:mh39-84901>
- Samory, M., Sen, I., Kohne, J., Floeck, F., & Wagner, C. (2021). "Call me sexist, but...": Revisiting Sexism Detection Using Psychological Scales and Adversarial Samples. <https://arxiv.org/abs/2004.12764>
- Saraswat, P. (2022). Supervised Machine Learning Algorithm: A Review of Classification Techniques. In F. P. G. Márquez (Hrsg.), *International Conference on Intelligent Emerging Methods of Artificial Intelligence & Cloud Computing* (S. 477–482). Springer International Publishing.
- Schmid, H. (1994). Probabilistic Part-of-Speech Tagging Using Decision Trees. *Proceedings of the International Conference on New Methods in Language Processing*, 154–164.
- Schmid, H. (1995). Improvements in Part-of-Speech Tagging with an Application to German. <http://www.cis.uni-muenchen.de/~schmid/tools/TreeTagger/>
- Schölkopf, B., & Smola, A. J. (2002). *Learning with kernels : support vector machines, regularization, optimization, and beyond*. MIT Press. <http://www.worldcat.org/oclc/48970254>
- Schütz, M., Boeck, J., Liakhovets, D., Slijepčević, D., Kirchknopf, A., Hecht, M., Bogensperger, J., Schlarb, S., Schindler, A., & Zeppelzauer, M. (2022). Automatic Sexism Detection with Multilingual Transformer Models. <https://arxiv.org/abs/2106.04908>
- Shathik, J. A., & Karani, K. P. (2020). A Literature Review on Application of Sentiment Analysis Using Machine Learning Techniques, 2581–7000. <https://doi.org/10.5281/zenodo.3977576>
- Shiri, F. M., Perumal, T., Mustapha, N., & Mohamed, R. (2023). A Comprehensive Overview and Comparative Analysis on Deep Learning Models: CNN, RNN, LSTM, GRU. <https://arxiv.org/abs/2305.17473>
- Siegel, M., & Alexa, M. (2020, Januar). *Sentiment-Analyse deutschsprachiger Meinungsäußerungen: Grundlagen, Methoden und praktische Umsetzung*. <https://doi.org/10.1007/978-3-658-29699-5>

- Struß, J., Siegel, M., Ruppenhofer, J., Wiegand, M., & Klenner, M. (2019). Overview of GermEval Task 2, 2019 Shared Task on the Identification of Offensive Language.
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (Second). The MIT Press. <http://incompleteideas.net/book/the-book-2nd.html>
- Sutton, R., & Barto, A. (1998). Reinforcement Learning: An Introduction. *IEEE Transactions on Neural Networks*, 9(5), 1054–1054. <https://doi.org/10.1109/TNN.1998.712192>
- Swim, J. K., Mallett, R., & Stangor, C. (2004). Understanding Subtle Sexism: Detection and Use of Sexist Language. *Sex Roles*, 51(3), 117–128. <https://doi.org/10.1023/B:SERS.0000037757.73192.06>
- Tate, A. (2023). When To Choose Density-Based Methods: Compare, k-means, DBSCAN and Hierarchical Clustering [Online; last checked: 27.07.2024]. <https://hex.tech/blog/comparing-density-based-methods/>
- Uysal, A. K., & Gunal, S. (2014). The impact of preprocessing on text classification. *Information Processing & Management*, 50(1), 104–112. <https://doi.org/https://doi.org/10.1016/j.ipm.2013.08.006>
- van Niekerk, D., Pérez-Ortiz, M., Shawe-Taylor, J., Orlič, D., Drobnjak, I., Kay, J., Siegel, N., Evans, K., Moorosi, N., Eliassi-Rad, T., Tanczer, L. M., Holmes, W., Deisenroth, M. P., Straw, I., Fasli, M., Adams, R., Oliver, N., Mladenović, D., Aneja, U., & Janicky, M. (2024). Systematic Prejudices: An Investigation into Bias Against Women and Girls in Large Language Models [Online; last checked: 27.07.2024]. <https://unesdoc.unesco.org/ark:/48223/pf0000388971>
- Vapnik, V. N. (1995). *The nature of statistical learning theory*. Springer-Verlag New York, Inc.
- Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley-Interscience.
- Vapnik, V. N. (1963). Pattern recognition using generalized portrait method. *Automation and Remote Control*, 24, 774–780. <https://api.semanticscholar.org/CorpusID:115205884>
- Verdhan, V. (2020). Supervised Learning for Regression Analysis. In *Supervised Learning with Python: Concepts and Practical Implementation Using Python* (S. 47–116). Apress. https://doi.org/10.1007/978-1-4842-6156-9_2
- Wankhade, M., Rao, A. C. S., & Kulkarni, C. (2022). A survey on sentiment analysis methods, applications, and challenges. *Artif. Intell. Rev.*, 55(7), 5731–5780. <https://doi.org/10.1007/s10462-022-10144-1>
- Wiegand, M., Siegel, M., & Ruppenhofer, J. (2019). Overview of the GermEval 2018 Shared Task on the Identification of Offensive Language. In J. Ruppenhofer, M. Siegel & M. Wiegand (Hrsg.). Austrian Academy of Sciences. <https://nbn-resolving.org/urn:nbn:de:bsz:mh39-84935>
- Wippermann, C. (2022). Sexismus im Alltag. Wahrnehmungen und Haltungen der deutschen Bevölkerung [Online; last checked: 27.07.2024]. <https://www.bmfsfj.de/resource/blob/141246/b24dff04fcbf73ebf5e794a062e271ef/sexismus-im-alltag-pilotstudie-data.pdf>
- Xi, J., Spranger, M., & Labudde, D. (2018). Proceedings of the GermEval 2018 Workshop, 14th Conference on Natural Language Processing, KONVENS 2018, 131–.
- Zhang, J.-J., & Zhong, P. (2020). Learning Biased SVM with Weighted Within-Class Scatter for Imbalanced Classification. *Neural Processing Letters*, 51. <https://doi.org/10.1007/s11063-019-10096-8>
- Zhou, Z., & Liu, S. (2021). *Machine Learning*. Springer Nature Singapore. <https://books.google.de/books?id=Zd5hywEACAAJ>

Eidesstattliche Erklärung

Hiermit versichere ich – Markus Byhan – an Eides statt, dass ich die vorliegende Arbeit selbstständig und nur unter Verwendung der angegebenen Quellen und Hilfsmittel angefertigt habe.

Sämtliche Stellen der Arbeit, die im Wortlaut oder dem Sinn nach Publikationen oder Vorträgen anderer Autoren entnommen sind, habe ich als solche kenntlich gemacht.

Diese Arbeit wurde in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegt oder anderweitig veröffentlicht.

Hatten, 09. August 2024

Ort, Datum

Markus Byhan